Cuando el dato falla

Casos reales de errores en datos, en investigación e instituciones — Introducción a la Ciencia de Datos, Universidad de Montevideo

Por qué esta clase

- Un error de datos casi nunca avisa: el programa corre y el resultado parece razonable.
- Casos de hoy: una planilla, una conversión de fechas, una unidad, un archivo demasiado grande, un promedio, un algoritmo.
- Consecuencias: decisiones de política económica, una misión espacial perdida, personas acusadas sin base, datos de salud expuestos.
- Pregunta guía en cada caso: **¿qué control lo habría detectado?**

Parte 1 — En la investigación

Reinhart y Rogoff (2010)

- *Growth in a Time of Debt* (American Economic Review): con deuda pública mayor al 90 % del PIB, el crecimiento promedio era de **−0,1 %**. Fue muy citado en debates de política fiscal.
- En 2013 Herndon, Ash y Pollin intentaron replicarlo y hallaron tres problemas:
  1. Se dejaron afuera años de Australia, Canadá y Nueva Zelanda (1946–50).
  2. **Error de planilla**: el rango de una fórmula cortaba la lista y quedaban **fuera cinco países** (Australia, Austria, Bélgica, Canadá, Dinamarca): `L30:L44` en lugar de `L30:L49`.
  3. Se promediaron promedios por país, dando igual peso a un país con un año que a uno con muchos.
- Resultado con los datos completos y mejor ponderación: **+2,2 %**.

Reinhart y Rogoff en una imagen

Rango de la fórmula en la planilla: 20 países, 15 filas usadas



Quedaron fuera Australia, Austria, Bélgica, Canadá y Dinamarca

Publicado	Corregido
−0,1 %	**+2,2 %**

Crecimiento medio con deuda mayor al 90 % del PIB (Herndon, Ash y Pollin, 2013)

Reinhart y Rogoff: la lección

- Lo detectó una réplica: alguien volvió a hacer la cuenta con los datos originales.
- Controles posibles: contar cuántas observaciones entran al cálculo; comparar con un cálculo hecho en código; publicar datos y código.
- Conexión con el curso: unidad de observación, conteo de filas, reproducibilidad (clases 4, 7 y 1).

Nombres de genes convertidos en fechas

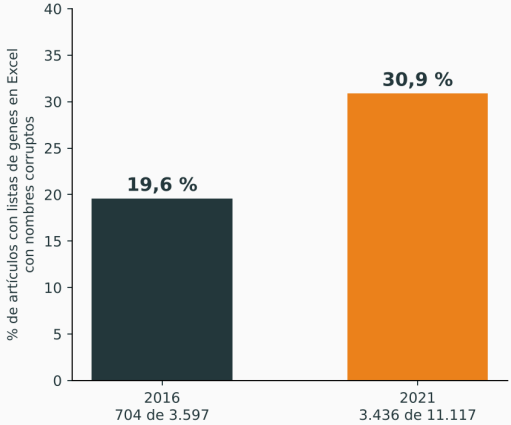
- Las planillas convierten por su cuenta lo que parece una fecha: el gen SEPT2 pasa a «2-sep» y MARCH1 a «1-mar». El nombre original se pierde.
- Ziemann y colaboradores (2016) revisaron 18 revistas de genómica: **704 de 3.597 artículos (19,6 %)** con listas de genes en Excel tenían nombres corruptos.
- Un estudio de 2021 (Abeysooriya y colaboradores), sobre artículos de 2014 a 2020, halló errores en **3.436 de 11.117 (30,9 %)**: conocer el problema no alcanzó.
- En 2020 el comité de nomenclatura de genes (HGNC) renombró los genes afectados: SEPT1 pasó a SEPTIN1, MARCH1 a MARCHF1. Se cambió el dato para adaptarlo a la herramienta.
- Control: declarar el tipo de cada columna (texto), conservar el archivo crudo intacto y verificar contra una lista oficial.

Genes y fechas en una imagen

Lo que ocurre en la planilla

Nombre del gen	Lo que muestra
SEPT2	2-sep
MARCH1	1-mar

El texto parece una fecha y se convierte

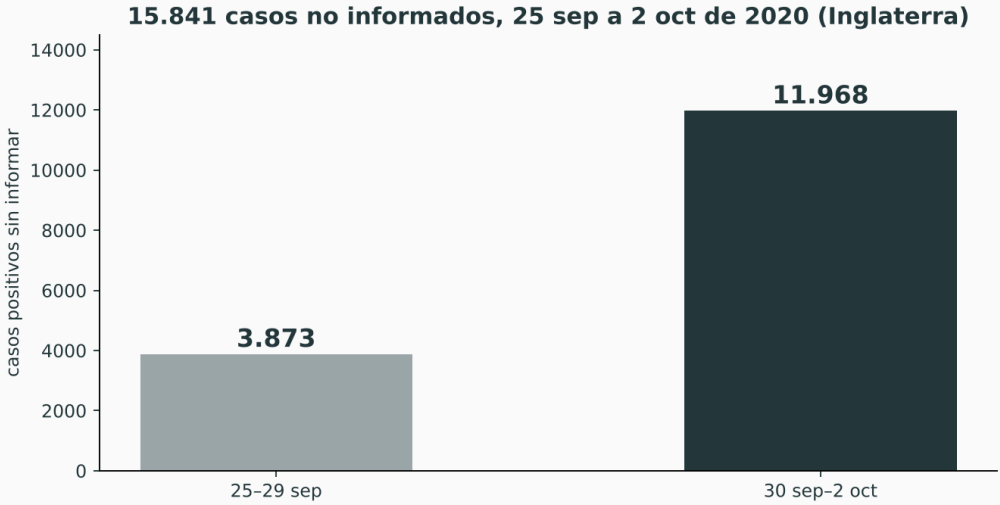


Parte 2 — En las instituciones

Salud pública, Inglaterra (2020)

- Entre el 25 de septiembre y el 2 de octubre de 2020 quedaron sin informar **15.841 casos positivos** de COVID-19; más del 75 % (11.968) correspondía a los últimos tres días.
- Según el organismo (Public Health England), algunos archivos con resultados positivos superaron el tamaño máximo que admitía el sistema de carga. La prensa lo atribuyó al límite de filas del formato `.xls` de Excel.
- Los casos se cargaron al sistema de rastreo de contactos recién a la 1 de la madrugada del 3 de octubre.
- Nadie recibió mal su resultado; el error estuvo en lo que llegó a quienes debían rastrear los contactos.
- Control: **conciliar filas de entrada y de salida** (la suma de n de la clase 7), alertas cuando un archivo crece.

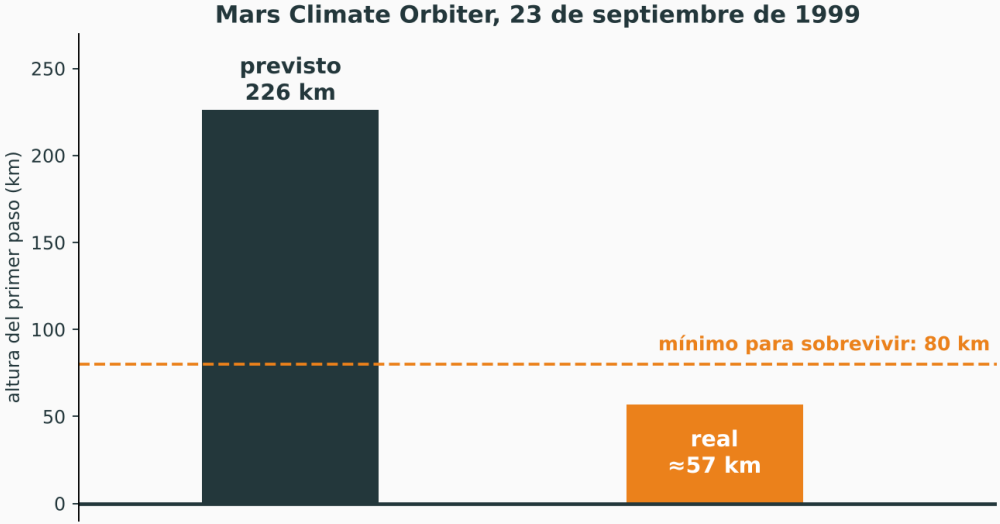
Salud pública, Inglaterra, en una imagen



NASA: Mars Climate Orbiter (1999)

- La sonda se perdió el 23 de septiembre de 1999 al llegar a Marte.
- Causa raíz según la junta de investigación: un archivo de software en tierra (`SM_FORCES`) entregaba el impulso de los propulsores en **libras-fuerza por segundo** y el sistema de navegación esperaba **newton por segundo**. Factor: 4,45.
- La altura prevista del primer paso era de 226 km; la real fue de unos 57 km, por debajo del mínimo de 80 km para sobrevivir.
- Durante el vuelo se habían visto discrepancias entre soluciones de navegación, pero solo se informaron de manera informal.
- Control: la **unidad en el diccionario de variables**, pruebas entre sistemas, y que las alertas se registren formalmente.

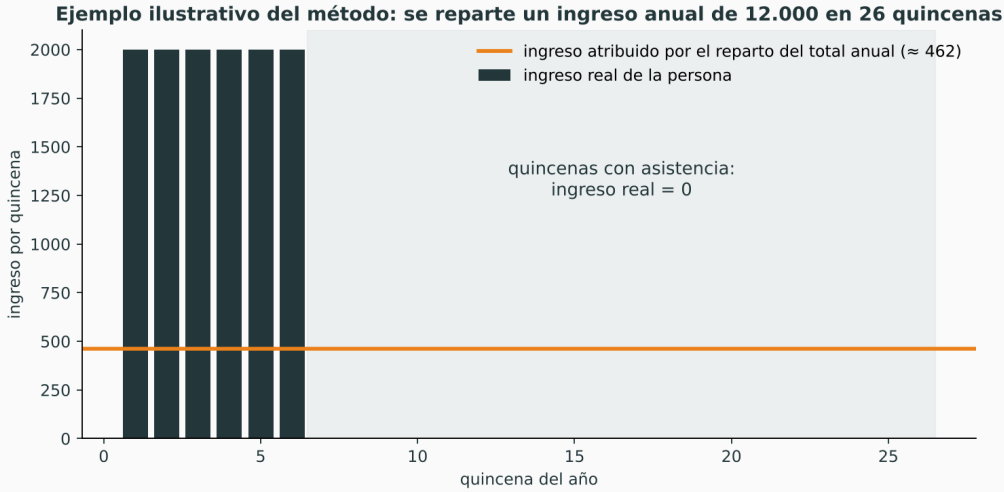
Mars Climate Orbiter en una imagen



Robodebt, Australia (2016–2020)

- El sistema comparaba el ingreso anual declarado al organismo tributario con los pagos de asistencia social, que se calculan por quincena. **Repartía el ingreso anual en partes iguales** entre las quincenas, como si la persona hubiera trabajado todo el año.
- Generó **470.000 deudas emitidas por error**. En 2019 el gobierno aceptó ante la justicia que el método era ilegal; el acuerdo colectivo fue de **1.872 millones de dólares australianos** (2021).
- La Comisión Real (informe del 7 de julio de 2023) lo calificó de «costoso fracaso de la administración pública».
- Error de datos: un supuesto (ingreso constante) aplicado a datos que no lo cumplen, **sin revisión de personas**.
- Control: probar el método con casos reales, supuestos escritos y revisados, revisión humana antes de actuar sobre personas.

Robodebt en una imagen



Subsidios de cuidado infantil, Países Bajos

- La administración tributaria usó un sistema de clasificación de riesgo de fraude en el que la **doble nacionalidad** pesaba como indicador.
- Unos **26.000 padres** fueron acusados injustamente entre 2005 y 2019; muchas familias quedaron con deudas de decenas de miles de euros.
- En julio de 2020 la autoridad de protección de datos concluyó que el sistema era ilícito y discriminatorio; el informe parlamentario «Ongekend onrecht» (diciembre de 2020) y la renuncia del gobierno (15 de enero de 2021) siguieron.
- Control: auditar qué variables entran a un modelo, medir efectos **por grupo** antes de usarlo, y supervisión humana con posibilidad real de apelar.

Cuidado infantil, Países Bajos, en una imagen



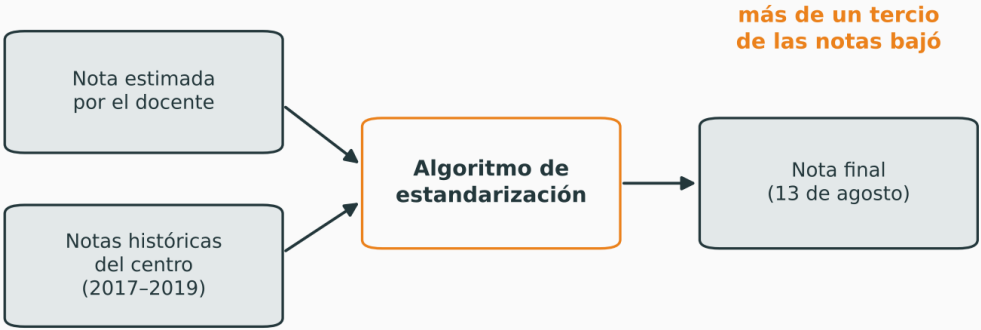
≈ 26.000 padres acusados injustamente, 2005–2019

Autoridad de protección de datos (2020): sistema ilícito y discriminatorio

Notas de bachillerato, Reino Unido (2020)

- Sin exámenes por la pandemia, un algoritmo ajustó las notas estimadas por los docentes usando la **distribución histórica de cada centro** (2017–2019).
- El 13 de agosto se publicaron resultados con **más de un tercio de las notas rebajadas** respecto de la estimación docente. En cursos de menos de 15 estudiantes se mantuvo la nota docente.
- El efecto cayó sobre estudiantes de centros públicos grandes; los centros privados, con cursos chicos, salieron beneficiados.
- El 17 de agosto se volvió a las notas de los docentes.
- Control: simular antes de aplicar, comparar efectos por tipo de centro, y un camino de apelación.

Notas de bachillerato, Reino Unido, en una imagen



Cursos de menos de 15 estudiantes: se mantiene la nota docente → beneficia a centros chicos y privados

17 de agosto: se vuelve a las notas de los docentes

Parte 3 — Datos personales y sensibles

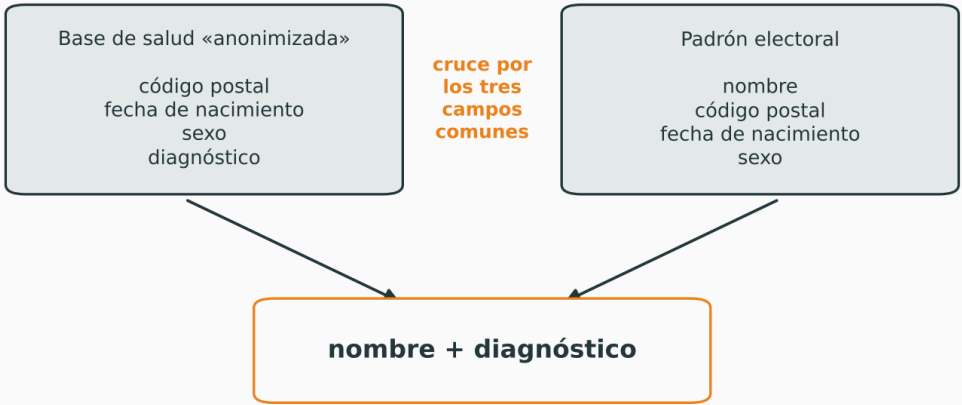
Qué dice la ley uruguaya (18.331)

- **Dato personal**: «información de cualquier tipo referida a personas físicas o jurídicas determinadas o determinables» (art. 4). *Determinables*: no hace falta el nombre.
- **Datos sensibles**: los que revelan «origen racial y étnico, preferencias políticas, convicciones religiosas o morales, afiliación sindical e informaciones referentes a la salud o a la vida sexual» (art. 4).
- El control está a cargo de la Unidad Reguladora y de Control de Datos Personales (URCDP).
- Los trabajos de los equipos con **salud mental, presión arterial e imágenes de rodilla** son datos de salud: sensibles.

Anonimizar no es quitar el nombre

- **Weld (1997).** Latanya Sweeney identificó al gobernador de Massachusetts en una base de salud «anonimizada» cruzándola con el padrón electoral por código postal, fecha de nacimiento y sexo.
- Sus estudios hallaron que cerca del **87 % de la población de Estados Unidos** queda identificada de manera única por esos tres datos.
- **Netflix (2006).** Se publicaron 100 millones de valoraciones de 480.000 usuarios, «anonimizadas». Investigadores las cruzaron con IMDb para identificar personas. Hubo una demanda y Netflix canceló la segunda competencia en 2010.
- Lección: las columnas inofensivas por separado identifican **combinadas** (cuasi-identificadores).

El caso Weld en una imagen



≈ 87 % de la población de EE. UU. es única por código postal + fecha de nacimiento + sexo (Sweeney)

Strava (2017–2018)

- La empresa publicó un mapa global de calor con las rutas de sus usuarios, con datos «anónimos».
- En enero de 2018 un estudiante mostró que el mapa revelaba **bases militares** y sus rutinas, incluidas bases de Estados Unidos en Siria y Afganistán y una base naval británica.
- Ningún dato individual tenía nombre: el problema estaba en **la agregación y el contexto**.
- Control: evaluar qué revela el conjunto, no solo cada registro; minimizar lo que se recoge; defaults de privacidad que protejan.

Parte 4 — Los datos como activos

Los datos como activos

- Un activo es algo que **tiene valor, cuesta mantener y hay que gestionar**. Los datos cumplen las tres condiciones.
- **Valor**: sirven para decidir, para operar, para entrenar modelos y para ofrecer servicios.
- **Costo**: recoger, almacenar, limpiar, documentar y proteger.
- **Riesgo**: un dato mal hecho, perdido o filtrado genera daños, reclamos y sanciones.
- Por eso un dato es a la vez un activo y un pasivo, y alguien tiene que hacerse cargo.

Ciclo de vida de un dato

Un dato es a la vez un activo (valor) y un pasivo (costo y riesgo)



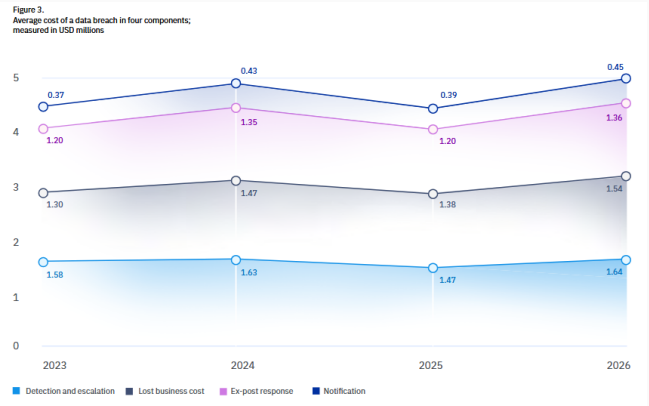
Qué cuesta que los datos sean malos

- Redman (*Harvard Business Review*, 2016) cita una estimación de IBM de **3 billones de dólares por año** para la economía de Estados Unidos por datos de mala calidad. Es una estimación gruesa, no una medición.
- Costos directos: tiempo de personas rehaciendo trabajo, decisiones equivocadas, reclamos y sanciones.
- Los casos de hoy lo ilustran: Robodebt terminó en un acuerdo de 1.872 millones de dólares australianos, el error de Inglaterra retrasó el rastreo de contactos y el de unidades costó una misión.

Cuando el activo se filtra

- **Equifax (2017):** datos personales de **147 millones de personas** expuestos; acuerdo de hasta **700 millones de dólares** con la FTC, la CFPB y los estados (julio de 2019).
- **IBM, *Cost of a Data Breach* 2026:** costo promedio global de una filtración de **4,99 millones de dólares**, un récord (+12 % sobre el año anterior).
- Cuanto más dato se acumula sin necesidad, más hay para perder. Principio de **minimización**: recoger solo lo necesario para la finalidad declarada, y eliminarlo cuando deja de servir.

Cuánto cuesta una filtración: el gráfico de IBM



Costo promedio de una filtración de datos en cuatro componentes, en millones de dólares. Fuente: IBM, *Cost of a Data Breach Report 2026*, figura 3.

Cómo se lee el gráfico

- Cada línea es un **componente del costo** de una filtración, en millones de dólares, para los años 2023 a 2026. Los números junto a cada punto son el valor de ese componente.
- Las líneas están **apiladas**: la altura de cada una es la suma de ese componente y de los que están debajo. La línea de arriba es el **total**.
- Control: $1{,}64 + 1{,}54 + 1{,}36 + 0{,}45 = 4{,}99$ millones en 2026. Los totales de 2023, 2024 y 2025 dan 4,45, 4,88 y 4,44.
- El total subió cerca de 12 % entre 2025 y 2026 (de 4,44 a 4,99).
- En cada año el componente mayor es la detección y el escalamiento; el menor, la notificación.

Los cuatro componentes

Componente	Qué incluye (según la metodología de IBM)	2026	%
Detección y escalamiento	Investigación forense, auditorías, gestión de la crisis, comunicación a la dirección	1,64	33
Negocio perdido	Interrupción de la operación, ingresos perdidos, clientes que se van, deterioro de la reputación	1,54	31
Respuesta posterior	Atención a afectados, monitoreo de crédito o identidad, costos legales, multas	1,36	27
Notificación	Avisar a las personas afectadas, a los reguladores y a terceros	0,45	9
Total		**4,99**	**100**

Valores en millones de dólares. Lo que más pesa no es la multa sino **encontrar el problema y perder negocio**: la confianza de quienes entregaron sus datos es parte del activo.

Gestionar un activo de datos

Práctica	Qué resuelve	Dónde la vimos
Diccionario de variables y libro de códigos	Significado, unidad, tipo	Clases 3 y 6
Perfilado y controles de cierre	Calidad	Clases 4 y 7
Código reproducible y Git	Trazabilidad	Clase 1
Dato crudo intacto, versiones	Poder volver atrás	Clases 4 y 5
Responsable y control de acceso	Quién puede usar qué	Ley 18.331
Finalidad, minimización y retención	Riesgo y cumplimiento	Ley 18.331

El caso uruguayo

- La Ley 18.331 (2008) y la URCDP regulan el uso de datos personales.
- Según la Comisión Europea, Uruguay tiene una **decisión de adecuación** (2012), mantenida en la revisión de enero de 2024: los datos personales pueden circular desde la Unión Europea hacia Uruguay sin garantías adicionales.
- Cumplir la ley es también un activo comercial: abre mercados y da confianza a quienes entregan sus datos.

Parte 5 — Qué hace la profesión

Qué controles habrían evitado cada caso

Caso	Qué falló	Control
Reinhart y Rogoff	Rango de planilla excluyó 5 países	Contar n usado; replicar en código; compartir datos
Genes en Excel	Tipo inferido por la herramienta	Declarar tipo; guardar crudo intacto; verificar
Salud pública, Inglaterra	Archivos mayores al límite, sin aviso	Conciliar filas de entrada y salida
Mars Climate Orbiter	Unidades distintas entre sistemas	Unidad en el diccionario; pruebas entre sistemas
Robodebt	Promedio anual aplicado a datos quincenales	Probar con casos; revisión humana
Cuidado infantil, Países Bajos	Nacionalidad como indicador de riesgo	Auditar variables; efectos por grupo
Notas, Reino Unido	Historia del centro aplicada a cada estudiante	Simular; efectos por grupo; apelación
Weld, Netflix, Strava	Cuasi-identificadores y agregados	Generalizar; evaluar riesgo; minimizar datos

Por qué importa la profesión

- Detrás de cada una de esas filas había una persona con la tarea de verificar el dato, y no la hizo, no pudo hacerla o nadie la escuchó.
- Quien trabaja con datos decide qué se cuenta, cómo se une, qué se descarta y qué se publica, y esas decisiones afectan a otras personas.
- Las defensas son las que ya practicamos: perfilar antes y después, conteos de cierre, unidad y tipo en el diccionario, código reproducible, documentar los supuestos.
- Y una más: preguntar **sobre quién** son los datos, qué revelan juntos y quién puede resultar dañado.

Fuentes (1/3)

- Herndon, T., Ash, M. y Pollin, R. (2013, working paper PERI; *Cambridge Journal of Economics*, 2014). *Does high public debt consistently stifle economic growth? A critique of Reinhart and Rogoff*.
- Reinhart, C. y Rogoff, K. (2010). *Growth in a Time of Debt*. American Economic Review 100(2).
- Ziemann, M., Eren, Y. y El-Osta, A. (2016). *Gene name errors are widespread in the scientific literature*. Genome Biology 17:177. Abeysooriya, M. et al. (2021). PLOS Computational Biology 17(6): e1008984.
- Mars Climate Orbiter Mishap Investigation Board (1999). *Phase I Report*, 10 de noviembre de 1999.
- Public Health England (2020). *PHE statement on delayed reporting of COVID-19 cases*. gov.uk.

Fuentes (2/3)

- Royal Commission into the Robodebt Scheme (2023). *Report*. Australia.
- Tweede Kamer (2020). *Ongekend onrecht*. Autoriteit Persoonsgegevens (2020), informe sobre la administración tributaria.
- Ofqual (2020). Informes sobre las calificaciones de verano de 2020 (Inglaterra).
- Sweeney, L. (2000). *Simple demographics often identify people uniquely*. Carnegie Mellon University.
- Narayanan, A. y Shmatikov, V. (2008). *Robust de-anonymization of large sparse datasets*. IEEE Symposium on Security and Privacy.
- Uruguay. Ley 18.331 de Protección de Datos Personales (2008), art. 4.

Fuentes (3/3)

- Redman, T. (2016). *Bad Data Costs the U.S. $3 Trillion Per Year*. Harvard Business Review, 22 de septiembre de 2016.
- Federal Trade Commission. *Equifax Data Breach Settlement* (2019).
- IBM. *Cost of a Data Breach Report 2026*.
- Comisión Europea (2024). Informe de revisión de las decisiones de adecuación, COM(2024) 7 final; decisión sobre Uruguay (2012).
- Los gráficos de los casos son esquemas propios, hechos con las cifras de las fuentes citadas; el ejemplo de Robodebt es ilustrativo, con datos inventados.

Cifras contrastadas con las fuentes citadas; confirmar en la fuente primaria antes de proyectar.