

Diseño de encuestas

Del cuestionario a la tabla de datos

Las encuestas, que son



Las encuestas son herramientas descriptivas que emplean preguntas para recopilar información estadística sobre algún aspecto de una población.

¿Conviene hacer una encuesta?

Tres preguntas antes de empezar (Bulut):

1. **¿Hay tiempo?** Diseñar, probar y aplicar una encuesta de calidad lleva semanas. Si el plazo es menor que esa estimación, no es el instrumento adecuado.
2. **¿Hay recursos?** Tiempo de las personas, plataforma, incentivos, procesamiento. Sin eso, la encuesta se hace mal o no se termina.
3. **¿Ya existen los datos?** Antes de preguntar, buscar si otra fuente ya responde: registros administrativos, encuestas anteriores, datos transaccionales de la diapositiva anterior.

Una encuesta se justifica cuando lo que se necesita no está en ninguna otra parte: percepciones, intenciones, razones, o hechos que ningún sistema registra.

¿Es la encuesta la herramienta adecuada?

- Las encuestas son más adecuadas para recopilar datos sobre fenómenos humanos no observables. Estos incluyen actitudes, creencias y opiniones, pero también pueden incluir informes de comportamientos y acciones que de otro modo serían inmensurables (o muy difíciles de medir).
- El uso de una encuesta debe alinearse lógicamente con las preguntas subyacentes que se formulan y las variables o resultados que se estudian.
- Además, los investigadores deben describir claramente en sus artículos la justificación de esas medidas y el uso (o usos) posterior de una encuesta. Así como seguir los protocolos éticos y las leyes o reglamentaciones de uso y/o extracción de datos.

Objetivo del bloque

Al terminar, cada pregunta que se escriba en un cuestionario debería poder responder tres cosas:

1. Qué columna genera en la tabla de datos.
2. De qué tipo es esa columna.
3. Cómo se codifican las respuestas y los faltantes.

No se discute el objeto de estudio ni el marco teórico. Solo el armado.

La regla básica

Diseñar la tabla antes que el formulario.

- Filas: una por respondente.
- Columnas: una por variable.

Si no se puede dibujar la columna que produce una pregunta, la pregunta no va.

Cuestionario

P1. ¿En qué año está?

☐ 1.º ☒ 2.º ☐ 3.º ☐ 4.º

P2. ¿Vive en casa familiar?


☒ Sí ☐ No

P5. Gasto en comida, 30 días

\$ 4500

P7. Rubros (marque todas)

☒ Materiales ☐ Ropa ☒ Salidas



id	anio	vive_fam	gasto_com	rubro_mat
1	2	TRUE	4500	1
2	4	FALSE	8200	0
3	1	TRUE	NA	1

una fila por respondente · una columna por variable


Ponerse en el lugar del respondente


Dos objetivos del proceso de redacción (Bulut):

1. Leer cada pregunta como la leería alguien de la población, no como la lee quien la escribió. Lo que es obvio para el diseñador rara vez lo es para el respondente.
2. Escribir preguntas claras y breves que **distingan** a los respondentes. Una pregunta a la que todos contestan lo mismo no aporta información, aunque esté bien escrita.

Legibilidad: revisar ortografía y gramática, y medir la dificultad de lectura. Para textos en español existen adaptaciones del índice de Flesch (Fernández-Huerta, INFLESZ); un cuestionario para población general debería leerse sin esfuerzo a nivel de enseñanza media.

Pasos del diseño





Elementos

Un cuestionario completo tiene seis partes, no solo las preguntas (Bulut):

1. Título.
2. Texto introductorio.
3. Consentimiento o carta de información.
4. Instrucciones para completarlo.
5. Las preguntas.
6. Cierre y agradecimiento.

1 · Título

2 · Introducción

quién, para qué, cuánto lleva

3 · Consentimiento

finalidad y uso de los datos · Ley 18.331

4 · Instrucciones

5 · Preguntas

6 · Cierre y agradecimiento

Las partes 2 y 3 no son decoración

Ahí se cumple el principio de finalidad y el consentimiento informado. Sin ellas, los datos no se usan.

Esta clase trabaja en la parte 5

Pero el cuestionario que se entrega es el documento completo, de la 1 a la 6.

Una buena primera pregunta hace que la persona siga.

Las sensibles van al final.

Ejemplo de trabajo

Encuesta de gasto mensual a estudiantes universitarios. Once preguntas en tres bloques:

A. Perfil 1. ¿En qué año de la carrera está? 2. ¿Vive en la casa familiar? 3. ¿Cuánto paga de alquiler por mes? 4. ¿Trabaja actualmente?

B. Gastos en los últimos 30 días 5. ¿Cuánto gastó en comida fuera de casa? 6. ¿Cuánto gastó en transporte? 7. ¿En cuáles de estos rubros tuvo algún gasto? (marque todas) 8. ¿Lleva registro de sus gastos?

C. Ingresos y percepción 9. ¿Cuál es su principal fuente de ingresos? 10. ¿Cómo describiría su situación económica? 11. ¿Qué gasto le resulta más difícil de controlar?

Antes de seguir: ¿cuántas columnas tiene la tabla resultante?

Fundamentos

Fuente de datos

«Gasté unos
\$4.500 en comida»
(cree recordar)


Declaradas

lo que la persona dice
encuesta

CAFETERÍA		
03/09	café	120
05/09	almuerzo	380
09/09	café	120
...		
TOTAL 30 d		5.210

Reveladas

lo que la persona hace
transacciones, registros



Huella digital

lo que el sistema registra
logs, clics, ubicación

tres fuentes · tres columnas «gasto_comida» que no significan lo mismo

De dónde salen los datos sobre personas

Una encuesta es una de varias formas de generar datos. Se distinguen por quién decide qué se registra.

Fuente	Qué se registra	Quién decide qué se registra	Qué se obtiene	Qué se pierde
Preferencias declaradas (encuesta)	Lo que la persona dice	El diseñador del cuestionario	Percepciones, intenciones, razones; cualquier cosa que se pueda preguntar	Precisión: memoria, deseabilidad social, no respuesta
Preferencias reveladas (transacciones, registros administrativos)	Lo que la persona hace, inferido de sus elecciones	El sistema que opera la transacción	Comportamiento efectivo sin depender de la memoria ni de la honestidad	El “por qué”; todo lo que el sistema no registra

Huella digital (logs, clics, ubicación, tiempo en pantalla) | Comportamiento como subproducto de usar un sistema | Nadie, en el sentido de medición: es un residuo técnico | Volumen y granularidad | Definición: cada campo hay que reinterpretarlo como si fuera una pregunta |

En el ejemplo, “cuánto gastó en comida fuera de casa” se puede obtener de tres maneras: preguntándolo (P5), leyendo los cobros con tarjeta de estudiante en la cafetería, o leyendo los registros de una app de pedidos. Los tres producen una columna **gasto_comida** que no significa lo mismo.

La idea de preferencia revelada viene de Samuelson (1938): la elección observada informa sobre la preferencia mejor que la declaración. Lo que se pierde es la posibilidad de preguntar por lo que no ocurrió.



Datos de comportamiento sin preguntas

Cuando el dato no sale de un cuestionario, el libro de códigos igual hace falta. La diferencia es que hay que reconstruirlo:

- **Qué mide cada campo.** Un registro `monto` en una tabla de cobros: ¿incluye propina? ¿descuentos? ¿en qué moneda?
- **Qué unidad de análisis tiene.** Un log de la app registra sesiones, no personas. Pasar de sesión a persona es una decisión.
- **Qué faltantes hay y por qué.** Quien paga en efectivo no aparece en los cobros con tarjeta. Es un faltante estructural que nadie diseñó.
- **Quién queda afuera.** Solo se observa a quien usa el sistema. La cobertura la define la tecnología, no el investigador.

Los equipos que trabajan con datos transaccionales y con registros de uso de IA están en esta situación: tienen la tabla, y tienen que escribir el cuestionario que la habría producido.

Datos personales: marco legal en Uruguay

- **Ley 18.331** (2008), Protección de Datos Personales y Acción de Habeas Data. Reglamentada por el Decreto 414/009; modificada por la Ley 19.670 (2018), el Decreto 64/020 y la Ley 19.924 (2020). Órgano de control: URCDP.
- Alcanza a toda base de datos con información de personas identificadas o identificables, cualquiera sea su soporte y su origen: lo que se preguntó y lo que se registró sin preguntar.

Principios con consecuencia directa en el diseño:

Principio	Qué exige	En el cuestionario
Finalidad	Declarar para qué se recogen los datos y usarlos solo para eso	El propósito se escribe antes de la primera pregunta y no se cambia después
Consentimiento previo informado	Manifestación libre, expresa e inequívoca; no se infiere del silencio	Se registra que fue otorgado
Pertinencia	No recoger más de lo necesario para la finalidad	El criterio de longitud tiene base legal

Principio	Qué exige	En el cuestionario
Seguridad y reserva	Proteger los datos y no divulgarlos	Separar identificadores de respuestas
Derechos del titular	Acceso, rectificación, supresión	Hay que poder encontrar a una persona en la base y borrarla

Datos sensibles e identificación

Datos sensibles (art. 18): origen racial o étnico, preferencias políticas, convicciones religiosas o morales, afiliación sindical, salud, vida sexual. Solo se recogen con consentimiento expreso y por escrito, y con justificación.

Si una pregunta cae en esa lista, la pregunta que corresponde es si hace falta.

Identificación:

- **id** es un número correlativo, no la cédula ni el correo.
- Si hay que volver a contactar a la persona, los datos de contacto van en una tabla separada, vinculada por **id** , con acceso restringido.
- Una tabla sin nombres puede seguir identificando: año de carrera, alquiler exacto y fuente de ingresos “Otro: trabajos freelance” pueden bastar para reconocer a alguien en una facultad chica. Anonimizar es más que borrar una columna.

La aplicación a un caso concreto requiere asesoramiento jurídico; lo que corresponde al diseñador de la encuesta es saber que estas obligaciones existen antes de salir a campo.

Con identificadores

nombre	cedula	anio	alquiler
M. Pérez	4.812.1...	2	NA
J. Silva	5.204.1...	4	12000
A. Rocha	5.531.1...	3	9000

borrar



Sin identificadores... ¿anónima?

id	anio	alquiler	fuentes_otro
1	2	NA	NA
2	4	12000	NA
3	3	9000	freelance

En una facultad chica, «tercer año, paga 9.000 de alquiler, hace trabajos freelance» identifica a una persona.
Combinar columnas inocuas puede reidentificar. Anonimizar es más que borrar una columna.

Datos de contacto: en otra tabla, unida por id

Una pregunta es una medición

Operacionalización: el camino desde lo que se quiere saber hasta la columna.


concepto → dimensión → indicador → pregunta → variable

En el ejemplo:

Concepto	Dimensión	Indicador	Pregunta	Variable
Situación económica	Percepción subjetiva	Autoevaluación 1–5	P10	situacion
Situación económica	Gasto efectivo	Monto en comida, 30 días	P5	gasto_comida
Situación económica	Gasto efectivo	Monto en transporte, 30 días	P6	gasto_transporte

Un concepto suele necesitar varias columnas. Una columna nunca es el concepto: es un indicador de una de sus dimensiones.

“Diseñar la tabla antes que el formulario” es esto: decidir qué indicadores se necesitan antes de escribir cómo se preguntan.



Un concepto necesita varias columnas; una columna nunca es el concepto

Niveles de medición

Stevens (1946) distingue cuatro niveles según qué operaciones tienen sentido sobre los valores:

Nivel	Qué se puede hacer	Ejemplo	En la tabla
Nominal	Distinguir categorías	fuelle de ingresos	fuelle_ingreso
Ordinal	Ordenarlas	año de carrera, escala 1–5	anio , situacion
Intervalo	Medir distancias; el cero es convencional	temperatura en °C	(no hay en el ejemplo)
Razón	Distancias y cocientes; el cero es real	pesos gastados	gasto_comida

- Cada nivel permite lo del anterior y algo más.
- El diseño de la pregunta fija el nivel. Después no se puede subir: de tramos no se recupera el monto.
- Sí se puede bajar: de `gasto_comida` se construyen tramos cuando haga falta.
- Promediar una escala 1–5 es tratar una ordinal como de intervalo. Se hace con frecuencia; lo que no se hace es sin declararlo.

Validez y confiabilidad

Dos propiedades de una pregunta como instrumento de medición:

- **Validez:** mide lo que dice medir. *¿Está conforme con lo que gasta en comida y en transporte?* no mide ninguna de las dos cosas por separado.
- **Confiabilidad:** mide lo mismo cada vez que se aplica. *¿Cuánto gasta en transporte?* sin período de referencia recibe respuestas distintas de la misma persona según el día.


La sección de redacción que sigue es una lista de formas conocidas de perder validez o confiabilidad.

Fuentes de error

Marco de error total de encuesta (Groves et al. 2009). Cuatro fuentes, en el orden en que aparecen:

Fuente	Qué es	Dónde se controla
Cobertura	La lista de la que se saca la muestra no contiene a toda la población	Marco muestral
Muestreo	Se observa una parte, no el todo	Diseño muestral
No respuesta	Personas seleccionadas que no contestan, o ítems que quedan en blanco	Longitud, orden, redacción
Medición	La respuesta registrada no coincide con el valor verdadero	Redacción, opciones, escalas

Este bloque trabaja sobre las dos últimas. Cobertura y muestreo quedan para otra clase.



Marco de error total de encuesta (Groves et al., 2009)

Unidades

- **Población:** a quién se quiere describir.
- **Unidad de análisis:** sobre qué se hacen afirmaciones (una fila de la tabla).
- **Unidad de respuesta:** quién contesta el cuestionario.

En el ejemplo las tres coinciden: estudiantes de la facultad, un estudiante por fila, contesta el propio estudiante.

No siempre es así. En una encuesta de gasto de hogares la unidad de análisis es el hogar y responde un informante; en una encuesta a empresas responde una persona por la organización. Cuando no coinciden, el cuestionario tiene que decir explícitamente por quién se está respondiendo.

Tipos de pregunta y variable que generan

Opción única, sin orden

P9. ¿Cuál es su principal fuente de ingresos? ☐ Familia ☐ Trabajo ☐ Beca ☐ Ahorros ☐ Otro

- Una columna.
- Variable **categorica nominal**: las categorías no se ordenan.
- Se guarda como texto o como código numérico con etiqueta.

Opción única, con orden

P1. ¿En qué año de la carrera está? ☐ 1.º ☐ 2.º ☐ 3.º ☐ 4.º ☐ 5.º o más

- Una columna.
- Variable **ordinal**: hay orden, pero la distancia entre categorías no está definida.
- El orden debe quedar registrado explícitamente (no se infiere del texto).

Sí / No

P2. ¿Vive en la casa familiar? ☐ Sí ☐ No

- Una columna.
- Variable **binaria**. Es una nominal de dos categorías; conviene almacenarla como lógica (**TRUE / FALSE**) o como 0/1.

Escala de valoración

P10. ¿Cómo describiría su situación económica en los últimos 30 días? 1 Muy ajustada · 2 · 3 · 4 · 5 Muy holgada

- Una columna.
- Variable **ordinal**. Que los valores sean números no la vuelve cuantitativa.
- Tratarla como numérica (promediar, por ejemplo) es una decisión analítica que se toma después y se declara. No es una propiedad del dato.

Numérica directa

P5. ¿Cuánto gastó en comida fuera de casa en los últimos 30 días? \$ _____

- Una columna.
- Variable **cuantitativa** (continua; sería discreta para una cantidad de veces).
- Es la que más información conserva. El costo: preguntas difíciles de recordar o sensibles bajan la tasa de respuesta.

Numérica por tramos

P6. ¿Cuánto gastó en transporte en los últimos 30 días? ☐ Nada ☐ Hasta \$1.000 ☐ \$1.001 a \$3.000 ☐ \$3.001 a \$6.000 ☐ Más de \$6.000

- Una columna, **ordinal**.
- Se pierde la posibilidad de calcular promedios o de recortar tramos distintos después.
- Se gana tasa de respuesta. Es un intercambio que se decide antes de salir a campo, porque no se puede deshacer.

P5 y P6 preguntan lo mismo (un monto) con dos diseños distintos. Ninguno es correcto en general.

Selección múltiple

P7. ¿En cuáles de estos rubros tuvo algún gasto en los últimos 30 días? ☐ Materiales de estudio ☐ Salidas
☐ Ropa ☐ Suscripciones digitales ☐ Salud

No genera una variable. Genera una columna binaria por opción:

id	rubro_materiales	rubro_salidas	rubro_ropa	rubro_suscripciones	rubro_salud
1	1	1	0	1	0
2	0	1	1	1	0

Guardar la respuesta como un solo texto ("Salidas; Ropa; Suscripciones") es el error más frecuente en encuestas armadas sin pensar la tabla.

P7. ¿En cuáles de estos rubros tuvo algún gasto? (marque todas)

- ☒ Materiales de estudio
- ☒ Salidas
- ☐ Ropa
- ☒ Suscripciones digitales
- ☐ Salud



NO: una columna de texto

```
rubros = "Materiales; Salidas; Suscripciones"
```

no se puede filtrar, contar ni cruzar sin volver a procesar

SÍ: una columna binaria por opción

rubro_mat	rubro_sal	rubro_ropa	rubro_susc	rubro_salud
1	1	0	1	0

cinco opciones, cinco columnas: cada una se cuenta y se cruza sola

Pregunta abierta

P11. ¿Qué gasto le resulta más difícil de controlar? _____

- Una columna de **texto**.
- No se analiza directamente: requiere codificación posterior (leer, agrupar, asignar categorías). Es la pregunta más cara de procesar.
- Se justifica cuando no se conocen las categorías de antemano o cuando se quiere el lenguaje del respondente.

Resumen

Formato de pregunta	Columnas	Tipo de variable	En el ejemplo
Opción única sin orden	1	Nominal	P9
Opción única con orden	1	Ordinal	P1, P4, P8
Sí / No	1	Binaria	P2
Escala 1–5	1	Ordinal	P10
Número	1	Cuantitativa	P3, P5
Tramos	1	Ordinal	P6
Selección múltiple con k opciones	k	Binarias	P7
Abierta	1	Texto (a codificar)	P11

Once preguntas, diecisiete columnas.

Redacción de preguntas

Una idea por pregunta

¿Cree que la comida de la facultad es cara y de mala calidad?

Dos preguntas en una. Quien la considera cara pero de buena calidad no tiene respuesta. Cada pregunta mide una sola cosa. Si aparece una “y”, revisar.

Lenguaje neutro

¿No cree que debería ahorrar más?

Induce la respuesta y contiene una negación (responder “no” es ambiguo).

Formulación neutra: *¿Lleva registro de sus gastos?* o *¿Cómo describiría su situación económica?*

Período de referencia explícito

¿Cuánto gasta en transporte?

¿Por semana, por mes, en un mes típico, en el último mes? Cada persona responderá algo distinto.

¿Cuánto gastó en transporte en los últimos 30 días?

“Los últimos 30 días” y “un mes típico” no son equivalentes: uno pide recordar, el otro pide estimar. Se elige uno y se sostiene en todo el cuestionario.

Categorías exhaustivas y excluyentes

Alquiler mensual: ☐ Hasta \$8.000 ☐ \$8.000 a \$12.000 ☐ \$12.000 a \$20.000

- No excluyentes: 8.000 y 12.000 caen en dos tramos.
- No exhaustivas: más de 20.000 no tiene opción.

Toda respuesta posible debe tener exactamente una casilla.

Selección múltiple disfrazada

¿De dónde recibe ingresos? ☐ Familia ☐ Trabajo ☐ Ambos ☐ Otro

“Ambos” delata que la pregunta admite más de una respuesta. Hay dos salidas:

- Selección múltiple: una columna binaria por fuente.
- Opción única con la palabra *principal*: *¿Cuál es su principal fuente de ingresos?* (es lo que hace P9).

Opciones de respuesta

Escalas

- **Cantidad de puntos:** 4 obliga a tomar posición; 5 permite un punto neutro. Ninguna es correcta en general; se decide y se mantiene igual en todo el cuestionario.
- **Etiquetas:** etiquetar solo los extremos (1 = Muy ajustada, 5 = Muy holgada) o todos los puntos. Etiquetar todos reduce interpretaciones distintas.
- **Dirección:** mantener siempre el mismo sentido (mayor valor = mejor situación) para no confundir al respondente ni al analista.

Desequilibrada

una opción negativa, cuatro positivas: empuja hacia arriba



Equilibrada y ordenada

dos y dos, de negativo a positivo, etiquetas en todos los puntos



La misma dirección en todo el cuestionario: mayor valor, mejor

“Otro (especifique)” y “No sabe / No contesta”

- **Otro (especifique)** genera dos columnas: la categoría `Otro` en `fuentes_ingreso` y un campo de texto `fuentes_otro`. Si muchas respuestas caen en “Otro”, faltó una categoría.
- **No sabe / No contesta** es una decisión de diseño. Si se ofrece, hay que definir cómo se codifica y distinguirla de la no respuesta (dejar en blanco).

id	vive_fam	alquiler	gasto_comida	fuentes_otro
1	TRUE	NA	4500	NA
2	FALSE	12000	8200	NA
3	TRUE	NA	NA	NA
4	FALSE	9000	6000	freelance

 **Estructural**
el filtro lo saltó; no debía resp

 **No respuesta**
debía responder y no lo hizo

 **No aplica**
no eligió "Otro"; el campo no

Los tres se ven igual en la tabla.
Los distingue el libro de códigos.

Orden, filtros y longitud

Orden

- De lo general a lo específico.
- Preguntas sensibles (montos de ingreso, situación económica) al final: si la persona abandona, ya respondió el resto.
- Las primeras preguntas deben ser fáciles y claramente relacionadas con el tema anunciado.

En el ejemplo: el perfil va primero, los montos de gasto en el medio, ingresos y percepción al final.

Preguntas filtro

P2. ¿Vive en la casa familiar? ☐ Sí ☐ No → si Sí, pasar a P4 P3. ¿Cuánto paga de alquiler por mes? \$

Quien responde “Sí” en P2 no tiene P3. Esa celda queda vacía **por diseño**.

Son **faltantes estructurales**. No son lo mismo que la **no respuesta** (la persona debía contestar y no lo hizo). El libro de códigos debe distinguirlos.

Longitud

Cada pregunta tiene un costo: tiempo del respondente y tasa de abandono.

Criterio para conservar una pregunta: la columna que genera se usa en algún análisis previsto. Si no se sabe para qué se va a usar, se elimina.

Libro de códigos

Qué es

El diccionario de variables se escribe **antes** de salir a campo, no después. Es el mismo diccionario del Práctico A y lo que SPSS guarda como metadatos.

Variable	Etiqueta	Tipo	Valores	Faltante
<code>id</code>	Identificador	entero	1, 2, ...	no admite
<code>anio</code>	Año de la carrera	ordinal	1 < 2 < 3 < 4 < 5+	NA
<code>vive_familia</code>	Vive en la casa familiar	binaria	TRUE, FALSE	NA
<code>alquiler</code>	Alquiler mensual (pesos)	cuantitativa	≥ 0	NA si <code>vive_familia</code> = TRUE
<code>trabajo</code>	Situación laboral	ordinal	No < Menos de 20 h < 20 h o más	NA

Variable	Etiqueta	Tipo	Valores	Faltante
<code>gasto_comida</code>	Comida fuera de casa, 30 días (pesos)	cuantitativa	≥ 0	NA
<code>gasto_transporte</code>	Transporte, 30 días	ordinal	Nada < Hasta 1.000 < 1.001– 3.000 < 3.001– 6.000 < Más de 6.000	NA
<code>rubro_*</code> (5)	Tuvo gasto en el rubro	binaria	0, 1	NA
<code>registro</code>	Lleva registro de gastos	ordinal	Nunca < A veces < Siempre	NA
<code>fuentes_ingreso</code>	Principal fuente de ingresos	nominal	Familia, Trabajo, Beca, Ahorros, Otro	NA
<code>fuentes_otro</code>	Otra fuente (texto)	texto	libre	vacío si <code>fuentes_ingreso</code> $\neq$ Otro

Variable	Etiqueta	Tipo	Valores	Faltante
<code>situacion</code>	Situación económica, 30 días	ordinal	1 < 2 < 3 < 4 < 5	NA
<code>gasto_dificil</code>	Gasto difícil de controlar (abierto)	texto	libre	vacío

Convenciones de nombres

- Minúsculas, sin espacios ni tildes: `gasto_comida` , no `Gasto en comida` .
- Prefijo común para las binarias de una misma selección múltiple: `rubro_materiales` , `rubro_salidas` , `rubro_ropa` , ...
- El nombre describe el contenido, no la posición: `alquiler` , no `p3` .

Cómo queda la tabla

Lectura y tipos

R Python

```
library(tidyverse)
```

```
encuesta <- read_csv("encuesta_gasto.csv")  
glimpse(encuesta)
```

```
Rows: 4  
Columns: 17  
$ id                <dbl> 1, 2, 3, 4  
$ anio              <dbl> 2, 4, 1, 3  
$ vive_familia      <chr> "Sí", "No", "Sí", "No"  
$ alquiler          <dbl> NA, 12000, NA, 9000  
$ trabajo           <chr> "No", "Sí, 20 h o más", "No", "Sí, menos de 20 h"  
$ gasto_comida       <dbl> 4500, 8200, NA, 6000  
$ gasto_transporte  <chr> "1.001 a 3.000", "Más de 6.000", "Hasta 1.000", "Nada"  
$ rubro_materiales  <dbl> 1, 0, 1, 0  
$ rubro_salidas     <dbl> 1, 1, 0, 1  
$ rubro_ropa        <dbl> 0, 1, 0, 0  
$ rubro_suscripciones <dbl> 1, 1, 0, 1  
$ rubro_salud       <dbl> 0, 0, 0, 1  
$ registro          <chr> "A veces", "Siempre", "Nunca", "A veces"  
$ fuente_ingreso    <chr> "Familia", "Trabajo", "Familia", "Otro"  
$ fuente_otro       <chr> NA, NA, NA, "trabajos freelance"  
$ situacion         <dbl> 3, 2, 4, 3  
$ gasto_dificil     <chr> "salidas", "delivery", NA, "suscripciones"
```

```
import pandas as pd
```

```
encuesta = pd.read_csv("encuesta_gasto.csv")  
encuesta.dtypes
```

```
id                int64  
anio              int64  
vive_familia      object  
alquiler          float64
```

```
trabajo          object
gasto_comida     float64
gasto_transporte object
rubro_materiales int64
rubro_salidas    int64
rubro_ropa       int64
rubro_suscripciones int64
rubro_salud      int64
registro         object
fuente_ingreso   object
fuente_otro      object
situacion        int64
gasto_dificil    object
dtype: object
```

Tres faltantes de naturaleza distinta: **alquiler** en los respondentes 1 y 3 (filtro), **gasto_comida** en el 3 (no respuesta), **fuentes_otro** en 1, 2 y 3 (no aplica). La tabla no los distingue; el libro de códigos sí.

Declarar los tipos

R Python

```
encuesta <- encuesta |>
  mutate(
    anio = factor(anio, levels = 1:5, ordered = TRUE),
    vive_familia = vive_familia == "Sí",
    trabajo = factor(trabajo,
      levels = c("No", "Sí, menos de 20 h", "Sí, 20 h o más"), ordered = TRUE),
    gasto_transporte = factor(gasto_transporte,
      levels = c("Nada", "Hasta 1.000", "1.001 a 3.000",
        "3.001 a 6.000", "Más de 6.000"), ordered = TRUE),
    registro = factor(registro,
      levels = c("Nunca", "A veces", "Siempre"), ordered = TRUE),
    fuente_ingreso = factor(fuente_ingreso),
    situacion = factor(situacion, levels = 1:5, ordered = TRUE)
  )
```

```
$ anio          <ord> 2, 4, 1, 3
$ vive_familia  <lgl> TRUE, FALSE, TRUE, FALSE
$ trabajo       <ord> No, Sí, 20 h o más, No, Sí, menos de 20 h
$ gasto_transporte <ord> 1.001 a 3.000, Más de 6.000, Hasta 1.000, Nada
$ registro      <ord> A veces, Siempre, Nunca, A veces
$ fuente_ingreso <fct> Familia, Trabajo, Familia, Otro
$ situacion     <ord> 3, 2, 4, 3
```

```
encuesta["anio"] = pd.Categorical(encuesta["anio"],
  categories=[1, 2, 3, 4, 5], ordered=True)
encuesta["vive_familia"] = encuesta["vive_familia"] == "Sí"
encuesta["trabajo"] = pd.Categorical(encuesta["trabajo"],
  categories=["No", "Sí, menos de 20 h", "Sí, 20 h o más"], ordered=True)
encuesta["gasto_transporte"] = pd.Categorical(encuesta["gasto_transporte"],
  categories=["Nada", "Hasta 1.000", "1.001 a 3.000",
    "3.001 a 6.000", "Más de 6.000"], ordered=True)
encuesta["registro"] = pd.Categorical(encuesta["registro"],
  categories=["Nunca", "A veces", "Siempre"], ordered=True)
encuesta["fuente_ingreso"] = encuesta["fuente_ingreso"].astype("category")
```

```
encuesta["situacion"] = pd.Categorical(encuesta["situacion"],  
                                       categories=[1, 2, 3, 4, 5], ordered=True)
```

```
anio          category  
vive_familia  bool  
trabajo       category  
gasto_transporte category  
registro      category  
fuente_ingreso category  
situacion     category
```

El orden de las categorías se declara en el código porque no está en el archivo. Esa declaración sale del libro de códigos.

Ejercicio

De la tabla al cuestionario

Se quiere obtener esta tabla a partir de una encuesta a clientes de la cafetería de la facultad. Escribir el cuestionario que la produce: texto de cada pregunta, opciones de respuesta, orden y filtros.

Variable	Tipo	Valores	Faltante
id	entero	1, 2, ...	no admite
frecuencia	ordinal	Nunca < 1 a 3 veces < 4 a 8 veces < Más de 8 veces	NA
prod_cafe , prod_comida , prod_frias , prod_otros	binaria (×4)	0, 1	NA si frecuencia = Nunca
atencion	ordinal	1 < 2 < 3 < 4 < 5	NA si frecuencia = Nunca
pago_efectivo , pago_tarjeta , pago_transferencia	binaria (×3)	0, 1	NA si frecuencia = Nunca

Variable	Tipo	Valores	Faltante
estudiante	binaria	TRUE, FALSE	NA
edad	cuantitativa	años	NA
mejora	texto	libre	vacío

Qué se verifica

- Toda pregunta tiene período de referencia.
- Hay un filtro después de `frecuencia` y está indicado a dónde saltar.
- `prod_*` y `pago_*` salen de preguntas de selección múltiple, no de opción única con “ambos”.
- `atencion` tiene los extremos etiquetados y la misma dirección que el resto del cuestionario.
- `edad` está al final.
- Cuántas preguntas se necesitan para producir trece columnas.

Para la bitácora

Seis preguntas con problemas. Para cada una: identificar el problema, reescribirla y decir qué tipo de variable produce (y cuántas columnas).

1. ¿Está conforme con lo que gasta en comida y en transporte?
2. ¿No le parece que gasta demasiado en salidas?
3. ¿Cuánto gastó últimamente en ropa?
4. Gasto en transporte: ☐ \$0 a \$1.000 ☐ \$1.000 a \$3.000 ☐ \$3.000 a \$6.000
5. ¿Cómo paga sus gastos? ☐ Efectivo ☐ Tarjeta ☐ Ambos ☐ Transferencia
6. (Primera pregunta del cuestionario) ¿Cuál es el ingreso mensual exacto de su hogar?

Fuentes

- Bulut, O. *Survey Design 101, Part I: Introduction to Survey Design*. Centre for Research in Applied Measurement and Evaluation, University of Alberta. Base de las secciones sobre plan, escalas, estructura y piloto.
- Dillman, D. A., Smyth, J. D. y Christian, L. M. (2014). *Internet, Phone, Mail, and Mixed-Mode Surveys: The Tailored Design Method* (4.^a ed.). Wiley.
- Groves, R. M. et al. (2009). *Survey Methodology* (2.^a ed.). Wiley. Marco de error total.
- Johnson, R. L. y Morgan, G. B. (2016). *Survey Scales: A Guide to Development, Analysis, and Reporting*. Guilford. Escalas equilibradas y ordenadas.
- Lozano, L. M., García-Cueto, E. y Muñiz, J. (2008). Effect of the number of response categories on the reliability and validity of rating scales. *Methodology*, 4(2), 73–79.
- Samuelson, P. A. (1938). A note on the pure theory of consumer's behaviour. *Economica*, 5(17), 61–71.
- Stevens, S. S. (1946). On the theory of scales of measurement. *Science*, 103(2684), 677–680.
- Ley 18.331 (2008) y normativa complementaria. URCDP, Uruguay.

Speaker notes