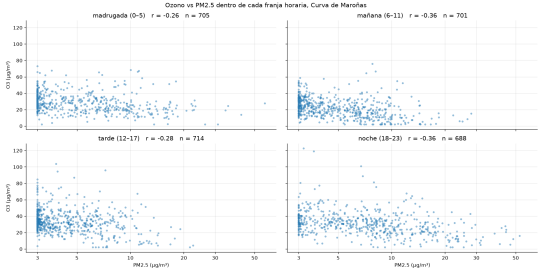
Series de tiempo: una primera mirada

Introducción a la Ciencia de Datos — clase 10

De dónde venimos



En la clase 9 unimos ozono y PM2.5 en Curva de Maroñas y encontramos $r = -0{,}26$. Al partir por franja horaria, r subía a $-0{,}3$ en cada franja: la hora del día estaba mezclada en la correlación.

Hoy el tiempo deja de ser un estorbo y pasa a ser el objeto de estudio.

- Qué es una serie de tiempo y qué exige.
- Sus componentes: tendencia, estacionalidad, irregular.
- La memoria de una serie: el correlograma.

Cada diapositiva dice qué sección del script la hace. Tres herramientas nuevas: `resample`, `rolling`, `shift`.

Qué es una serie de tiempo

Definición

Una **serie temporal** es una sucesión de observaciones de una variable tomadas a lo largo del tiempo, de manera que los valores aparecen ordenados en el tiempo (de la Fuente).

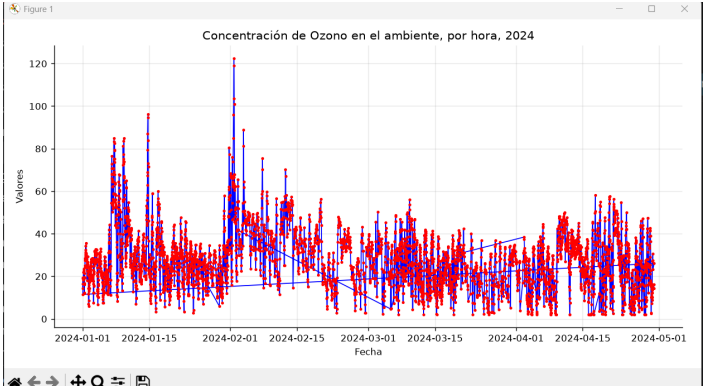
Tres condiciones para trabajarla:

1. **Ordenada:** la posición de cada dato es su fecha.
2. **Equidistante:** el intervalo entre dos observaciones consecutivas es el mismo en toda la serie.
3. **Sin huecos:** no faltan observaciones intermedias. Si faltan, se marcan como faltantes, no se saltan.

Una tabla con una columna `fecha` no es todavía una serie de tiempo: es una tabla. Se convierte en serie cuando el tiempo pasa a ser el índice y cumple las tres condiciones.

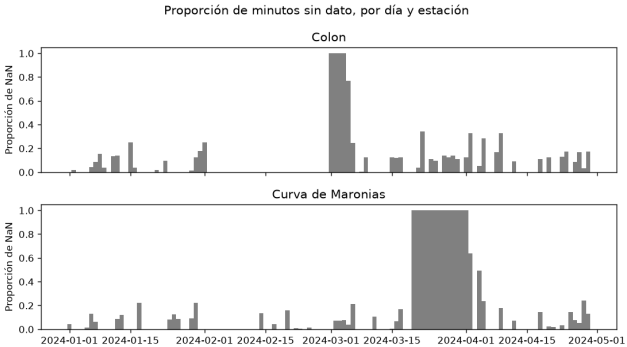
Script, sección 1: `set_index("fecha")["o3"].sort_index()`.

Una serie es de una sola cosa



- Este es el gráfico horario de la clase 7, con las dos estaciones en una sola línea. Las diagonales largas son la línea saltando de una estación a la otra.
- Una serie de tiempo es la sucesión de valores de **una** unidad observable (Mauricio): una estación, un producto, una cuenta. Dos unidades son dos series, y se dibujan como dos.
- Es el `filter(estacion == ...)` del script antes de `set_index`.

Sin huecos: se marcan, no se saltan



- Proporción de minutos sin dato por día (clase 7). Colón no midió del 1 al 8 de marzo; Curva de Maroñas, del 18 de marzo al 2 de abril.
- Si esas filas simplemente no están, “la observación anterior” al 3 de abril es la del 17 de marzo, y cualquier comparación con el pasado se rompe.
- La serie de tiempo conserva el lugar: el hueco es un `NaN` en su fecha.

Stock y flujo

De la Fuente distingue dos clases de magnitud:

- **Stock:** el valor en un instante. Concentración de ozono a las 15:00. Si se agregan minutos en una hora, se **promedia**.
- **Flujo:** lo acumulado desde la observación anterior. Vehículos que pasaron entre las 15:00 y las 16:00. Si se agregan minutos en una hora, se **suma**.

El valor de un flujo depende del intervalo elegido; el de un stock, no. Es la pregunta de la clase 7 (“¿qué estadístico representa el fenómeno?”) con nombre: antes de agregar, saber si la variable es stock o flujo.

Ozono y PM2.5 son stocks. El conteo vehicular es un flujo.

Por qué el paso tiene que ser fijo

Todo lo de hoy compara la serie con ella misma **k pasos atrás**. “k pasos atrás” significa “hace $k\times$ paso” solo si el paso es siempre el mismo y no falta ninguno.

Con una tabla que tiene huecos, “la fila anterior” a veces es el minuto anterior y a veces es tres horas antes. La comparación mezcla distancias distintas y no mide nada.

Primero, saber cuál es el paso real de cada sensor:

```
print(o3_s.index.to_series().diff().value_counts().head())
print(pm_s.index.to_series().diff().value_counts().head())
```

El valor más frecuente es el paso de muestreo; los demás son huecos o irregularidades. *Script, sección 2.*

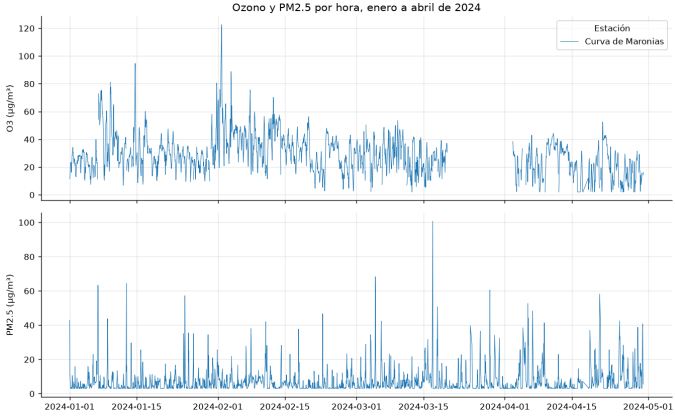
Cajas de tiempo: `resample`

```
serie = pd.DataFrame({
    "o3":   o3_s.resample(PASO).mean(),
    "pm25": pm_s.resample(PASO).mean(),
    "n_o3": o3_s.resample(PASO).count(),
    "n_pm": pm_s.resample(PASO).count(),
})
```

- Corta el tiempo en cajas de PASO alineadas al reloj (00:00, 00:10, …) y promedia lo que cae en cada una.
- Devuelve la grilla **completa**: caja vacía = NaN. Las tres condiciones de la definición quedan cumplidas.
- Las dos series quedan en las mismas cajas aunque sus sellos originales no coincidieran: es la unión de la clase 9, con el tiempo como clave.
- `count` dice cuántas mediciones respaldan cada valor (la cobertura de la clase 7).

El paso se elige con el diagnóstico anterior: el más corto que deje al menos una medición por caja en la serie más rala. *Script, sección 3.*

Mirar la serie completa



- Cuatro meses por hora, la estación en común, apilados. Se ve el nivel, si sube o baja, los huecos, y que el PM2.5 es de picos cortos sobre un piso.
- No se ve el ciclo diario: para eso se recorta una semana sobre el índice, `serie["2024-03-04":"2024-03-10"]`. Ninguna escala sola alcanza. *Sección 4.*

Componentes

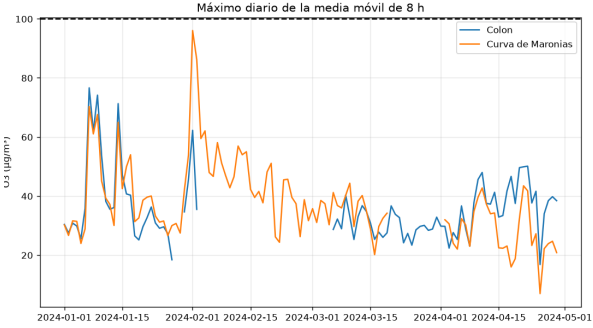
Los componentes de una serie

El análisis clásico (de la Fuente) descompone una serie en cuatro partes:

Componente	Qué es	En nuestros datos
Tendencia (T)	movimiento regular a largo plazo	el ozono baja de enero a abril
Estacional (E)	oscilación que se repite con período fijo	el ciclo de 24 h
Cíclica (C)	oscilación de medio plazo, período irregular	no se ve en 4 meses
Irregular (A)	lo esporádico e imprevisible	lo demás

Esquema **aditivo** ($Y = T + E + A$), que es el que usamos; el **multiplicativo** ($Y = T \cdot E \cdot A$) sirve cuando la oscilación crece con el nivel. En los manuales la “estación” es la del año; acá es la **hora del día** y el período es un día (144 pasos de 10 min). Misma idea, otra escala.

Tendencia: media móvil

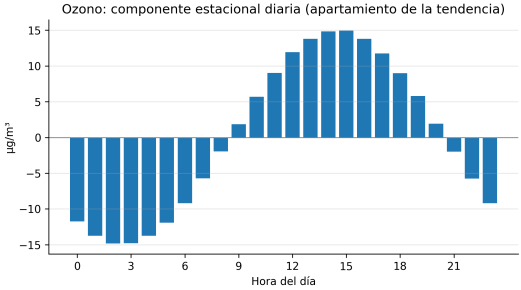


Ya vieron una media móvil: en la clase 7, la de 8 horas que usa la guía OMS. La misma herramienta, con otra ventana, estima la tendencia:

```
serie["o3_tend"] = serie["o3"].rolling(POR_DIA, center=True).mean()
```

- La ventana es el **período** (un día): al promediar un día entero, el ciclo diario se cancela y queda el nivel de fondo.
- `center=True`: cada valor va al centro de su ventana. Se pierde medio día en cada extremo. Una media móvil describe; **no predice**. *Sección 4b.*

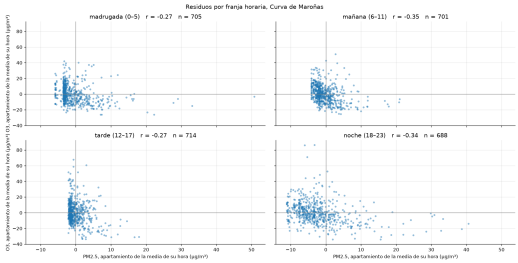
Estacionalidad: el perfil por hora




```
sin_tend = serie["o3"] - serie["o3_tend"]
perfil = sin_tend.groupby(serie.index.hour).mean()      # 24 valores
```

- Sacada la tendencia, queda estacional + irregular. Promediando por hora del día, lo irregular se cancela y queda el ciclo.
- Son los **índices estacionales** del esquema aditivo: cuánto se aparta cada hora de la tendencia. Suman aproximadamente cero.
- Es el perfil horario de la clase 9, ahora con nombre. *Script, sección 4c.*

Lo irregular

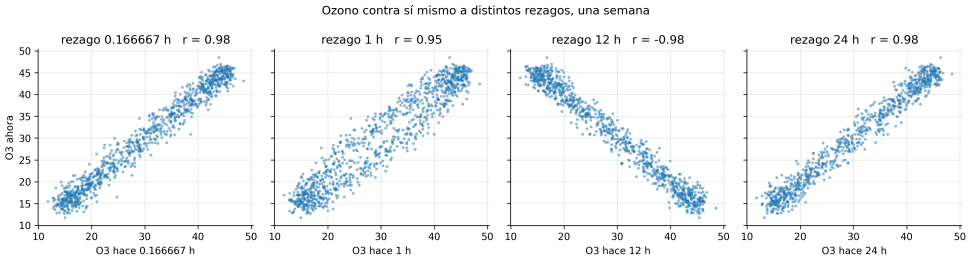



```
serie["o3_irreg"] = sin_tend - serie
```

- Lo irregular es lo que sobra: serie menos tendencia menos el índice de su hora. Cuánto ese día, a esa hora, se apartó de lo esperable.
- **Desestacionalizar** es restar el componente estacional (o dividir, en el esquema multiplicativo). La figura es eso, hecho en la clase 9 con la media de cada hora: los ejes ya son “apartamiento de lo normal para esa hora”.
- Describe la serie; no la explica. Qué produce el ciclo es una pregunta de la disciplina. *Sección 4c.*

Autocorrelación

La memoria de una serie: gráfico de rezago




```
ax.scatter(semana["o3"].shift(k), semana["o3"])
```

`shift(k)` corre la serie k renglones: en cada fila queda el valor de hace k pasos. Es una dispersión de la serie contra sí misma. *Script, sección 5.*

Autocorrelación

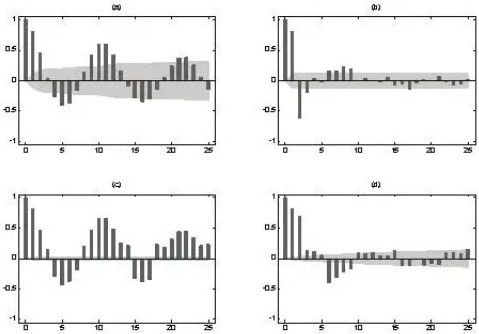
El r del gráfico de rezago es una correlación de Pearson entre dos tramos de la serie, cada uno con su media y su desvío. La **autocorrelación de orden k** fija la media y la varianza de toda la serie, las mismas para todo k:

$$r_k = \frac{\sum_{t=k+1}^{N} (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^{N} (y_t - \bar{y})^2}$$

```
x = (serie["o3"] - serie["o3"].mean()).fillna(0)   # NaN -> 0
acf = [(x * x.shift(k)).sum() / (x ** 2).sum() for k in rezagos]
```

- $r_0 = 1$ siempre; r_k alto: lo de ahora se parece a lo de hace k pasos.
- Un faltante reemplazado por la media aporta cero: es la convención de `acf()` en R y de `plot_acf` en Python, que calculan exactamente esto.
- La sucesión $r_1, r_2, \ldots$ es la **función de autocorrelación** (ACF); su gráfico de barras es el **correlograma** (Mauricio 2.2.9).
- La banda $\pm 1{,}96/\sqrt{N}$ es la referencia: una barra que la supera se toma como distinta de cero. Con N grande es muy angosta. *Sección 6*, una barra por hora de rezago, hasta 48 h.

Leer un correlograma

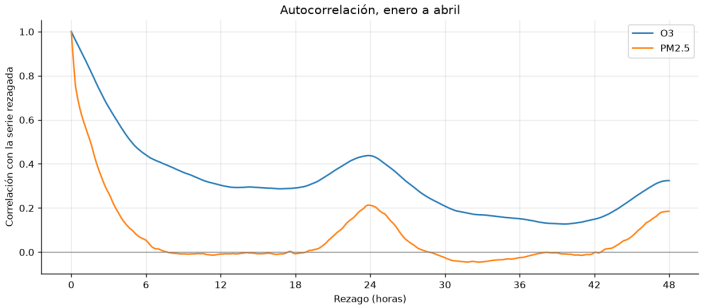


Formas típicas (Mauricio, cap. 2):

- **Cae rápido a cero** (b, d): poca memoria. Lo de hace unas horas ya no dice nada sobre ahora. En (b) solo importa el rezago 1.
- **Cae muy lento:** hay tendencia. Todo se parece a todo porque el nivel cambia despacio.
- **Sube y baja con período fijo** (a, c): hay estacionalidad. El correlograma repite el ciclo de la serie; en (c) el período es 12.

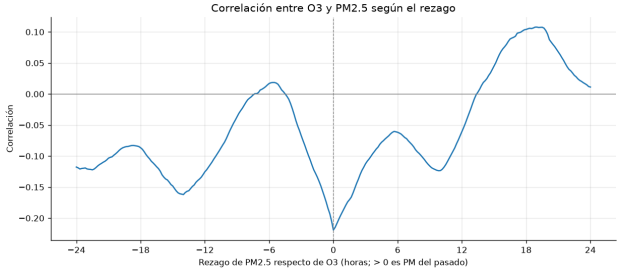
La banda gris es la referencia $\pm 1{,}96/\sqrt{N}$. Un correlograma real puede mostrar varias formas a la vez, en distintas zonas del eje.

Nuestro correlograma



- **Horas:** PM2.5 llega a cero en 7 h; el ozono a las 6 h sigue en 0,45. El ozono tiene más memoria de corto plazo.
- **24 y 48 h:** las dos tienen la joroba del ciclo diario. Modesta.
- **El piso del ozono:** entre 12 y 18 h de rezago no baja de 0,3. Los días se parecen a los días: regímenes que duran más de una jornada, y algo de la tendencia enero–abril. El PM2.5 no tiene ese piso.

Correlación cruzada



$$r_{xy}(k) = \frac{\sum_t (x_t - \bar{x})(y_{t-k} - \bar{y})}{\sqrt{\sum_t (x_t - \bar{x})^2 \, \sum_t (y_t - \bar{y})^2}}$$

- La misma construcción con dos series: ozono de ahora contra PM2.5 de hace k pasos, cada una centrada con su media. Es `ccf()` en R.
- En $k = 0$ es el r de la clase 9. El resto dice a qué distancia temporal la relación es más fuerte. Las dos series tienen ciclo diario, así que la curva también. *Script, sección 7.*

Cierre

Resumen

Concepto	Script	Herramienta
Serie de tiempo: valores a paso fijo, sin huecos	1	`set_index("fecha")`
Paso de muestreo	2	`diff().value_counts()`
Grilla completa por cajas	3	`resample(PASO).mean()`
Tendencia	4b	`rolling(POR_DIA, center=True)`
Estacional (perfil por hora)	4c	`groupby(index.hour).mean()`
Irregular (lo que sobra)	4c	una resta
Rezago	5	`shift(k)`
Autocorrelación r_k	6	la fórmula, en un `for`
Correlación cruzada $r_{xy}(k)$	7	ídem, con dos series

Bibliografía

- S. de la Fuente Fernández, *Estadística: Series temporales*, Universidad Autónoma de Madrid. Definición, stock y flujo, componentes, medias móviles, índices estacionales. Es la base de la primera mitad.
- J. A. Mauricio, *Introducción al Análisis de Series Temporales*, Universidad Complutense de Madrid, 2007. Capítulo 1 (definiciones, ejemplos de series) y sección 2.2 (ACF muestral, correlograma). Todo lo demás del libro es un curso aparte.

Datos: ozono y PM2.5, Curva de Maroñas, enero a abril de 2024, Catálogo de Datos Abiertos de Uruguay, Intendencia de Montevideo.