Preguntas, gráficos y una primera mirada a las series de tiempo

Introducción a la Ciencia de Datos

20 de octubre de 2026

Primera hora: qué preguntas responden los datos

Antes de los datos, la pregunta

Una **pregunta de ciencia de datos** es una pregunta que se puede responder con datos que existen o que se pueden obtener, mediante un análisis que se puede describir de antemano.

Leek y Peng (2015) observan que muchos errores de análisis no son errores de cálculo: son errores de **tipo de pregunta**. Se calcula bien una correlación y se la presenta como una causa; se describe una muestra y se la presenta como el país entero.

Hoy vamos a leer titulares reales de diarios uruguayos y preguntarnos tres cosas:

- qué pregunta hay detrás del titular, y de qué tipo es;
- qué datos y qué análisis harían falta para responderla;
- qué gráfico le falta a la noticia.

Seis tipos de pregunta (Leek y Peng, 2015)

Tipo	Qué busca	Ejemplo en los titulares
Descriptiva	Resumir los datos que se tienen	«El desempleo baja a 7% en junio»
Exploratoria	Buscar patrones no planteados de antemano	Desempleo por edad y sexo
Inferencial	De una muestra a la población, con incertidumbre	Encuesta de 900 casos, ± 3,3%
Predictiva	Anticipar un valor futuro o de un individuo	«¿A cuánto estará el dólar?»
Causal	Qué pasa con una variable si se cambia otra	Ley de alcohol cero y siniestros
Mecanística	Cómo, paso a paso, un cambio produce otro	Por qué el NO_2 tiene dos picos diarios

El tipo no lo decide el titular: lo decide qué datos hay y cómo se obtuvieron.

Las confusiones más frecuentes

Exploratoria leída como causal. Dos variables se mueven juntas (café y longevidad, hogares unipersonales y alquileres) y el titular dice que una causa la otra. Faltan el grupo de comparación y las variables que podrían explicar las dos.

Descriptiva leída como inferencial. Una muestra autoseleccionada (responde quien quiere, por internet) se presenta como la opinión del país.

Inferencial sin incertidumbre. «La pobreza bajó de 17,3% a 16,6%»: si la diferencia es menor que el margen de error, los datos no permiten afirmar que bajó.

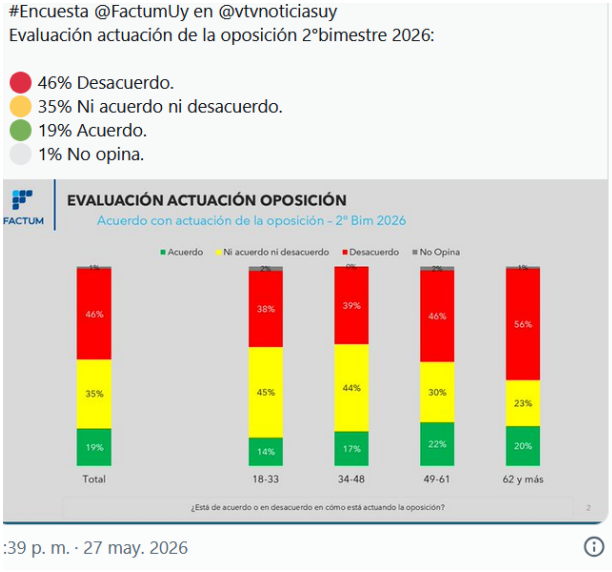
Cambio de medición leído como cambio de realidad. Una nueva metodología de pobreza, más cámaras que registran accidentes, denuncias en lugar de delitos.

Tipo de pregunta y tipo de análisis

El tipo de análisis depende de la **estructura de los datos**, que es lo que organiza el programa del curso:

Estructura de los datos	Análisis	Titulares
Una variable medida a intervalos regulares	Serie temporal	Desempleo mensual, homicidios por semestre
Unidades clasificadas en grupos	Comparación entre grupos	Desempleo por edad, pobreza por tramo
Dos variables en las mismas unidades	Correlación, dispersión	Educación y desempleo
Unidades ubicadas en el espacio	Datos espaciales	Pobreza por municipio
Antes y después de una intervención	Antes/después	Alcohol cero, regulación del cannabis
Intervenidos y no intervenidos	Grupo de control, diferencias en diferencias	Uruguay contra Chile

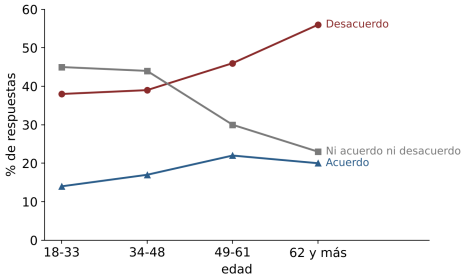
Un mismo dato, tres gráficos: el gráfico que publicó Factum



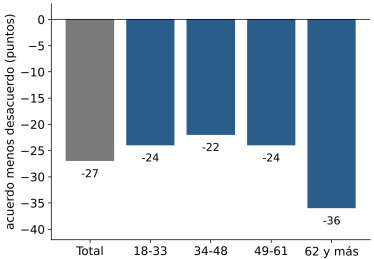
Factum, segundo bimestre de 2026, 900 casos por celular. Barras apiladas al 100% por edad. Abajo y arriba se comparan bien: comparten una base. El segmento del medio no: cada uno empieza a otra altura.

El semáforo carga de juicio las respuestas y confunde a quien no distingue rojo y verde.

Un mismo dato, tres gráficos: líneas y saldo



Con la edad, lo neutral pasa a desacuerdo. El acuerdo casi no cambia.



Saldo neto = acuerdo menos desacuerdo. Casi igual bajo los 62 años.

Actividad: titulares

Cada equipo recibe tres tarjetas con titulares reales y el texto de la noticia. Para cada una:

1. Identificar la pregunta que hay detrás del titular y clasificarla.
2. Indicar el tipo de análisis que usa o necesitaría.
3. Indicar qué datos se necesitan para responderla.
4. Dibujar el gráfico que le falta a la noticia, con los datos del texto si alcanzan: tipo de gráfico, variable de cada eje, qué representa cada punto o barra.

Para ir más lejos. Decidir si el titular afirma más de lo que los datos permiten y reescribirlo para que diga solo lo que los datos sostienen.

El gráfico se dibuja a mano. Al final, cada equipo presenta una tarjeta y su gráfico.

Segunda hora: una primera mirada a las series de tiempo

Lo que los diarios hacen sin decirlo

Tres titulares de la primera hora comparan de una manera particular:

- «Desempleo inició 2026 con una suba **respecto a diciembre** de 2025»
- «Salario real aumentó en junio un 0,88% **en comparación interanual**»
- «Los delitos bajaron 3,7% en el primer semestre de 2026 **respecto a igual período** de 2025»

¿Por qué comparar junio con junio, y no junio con mayo? Porque hay variables que cambian con la época del año, y comparar meses distintos mezcla ese cambio con el que nos interesa.

Para razonar sobre esto necesitamos un objeto nuevo: la **serie de tiempo**.

Qué es una serie de tiempo

Definición. Una serie de tiempo es un registro sistemático a lo largo del tiempo de una variable de interés (Rincón y De Jesús Romo, 2024). Se escribe

$$x_1, x_2, \dots, x_n,$$

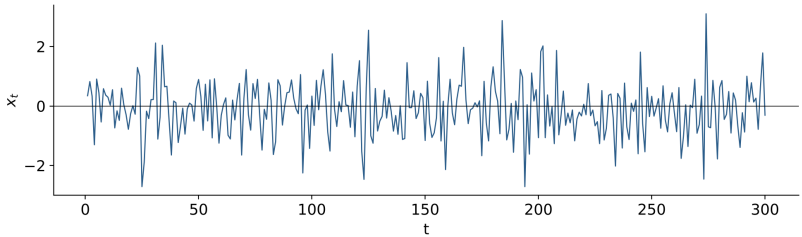
donde x_t es el valor observado en el momento t.

Tres condiciones prácticas (de la Fuente; Mauricio):

- **Ordenada**: el orden de las observaciones es parte del dato.
- **A intervalos iguales**: cada hora, cada mes, cada año.
- **De una sola unidad**: una estación, un país, una empresa. Dos unidades son dos series.

Se estudian para **describir, interpretar, controlar y pronosticar** el comportamiento de la variable (Rincón y De Jesús Romo, 2024).

Primer modelo elemental: el ruido blanco



Definición. Un **ruido** es una sucesión $Z_1, Z_2, ...$ de variables aleatorias independientes, todas con la misma distribución, de media μ y varianza σ^2. Si además son normales con media 0 se llama **ruido blanco**, $Z_t \sim WN(0, \sigma^2)$.

Lo que pasó en t no dice nada sobre lo que pasa en $t+1$: no hay memoria.

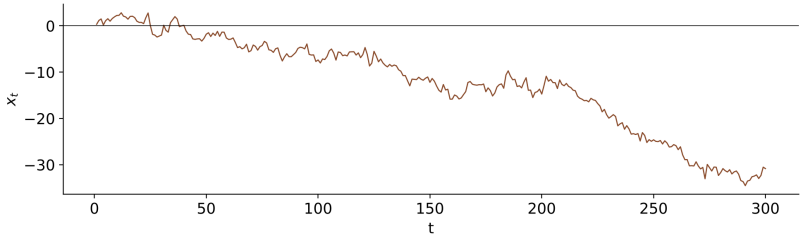
Para qué sirve el ruido blanco

Es el modelo de lo impredecible. Describe la parte de una serie que no se puede anticipar a partir de su pasado: por ejemplo, el error de medición de un sensor. Si una serie es ruido, el mejor pronóstico es siempre su media, sin importar lo que pasó antes.

Es la pieza con la que se construyen los demás modelos. La caminata aleatoria, que viene a continuación, es una suma de ruidos. Los modelos que veremos en las próximas clases también se arman a partir de un ruido.

Es la referencia para leer un correlograma. Cuando se calcule la autocorrelación de una serie, la pregunta será si se distingue de la de un ruido. Si no se distingue, en esa serie no hay memoria que aprovechar.

Segundo modelo elemental: la caminata aleatoria



Definición. Una **caminata aleatoria** acumula ruidos:

$$X_t = X_{t-1} + Z_t, \qquad X_0 = x_0.$$

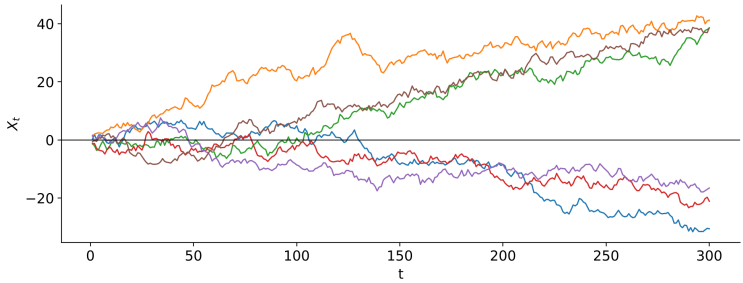
Cada valor es el anterior más un paso al azar. Desarrollando:
$X_t = x_0 + Z_1 + Z_2 + \cdots + Z_t.$

Para qué sirve la caminata aleatoria

Es el modelo más simple de un precio. Un tipo de cambio o el precio de una acción se parecen a una caminata: cada día parten del valor del día anterior y se mueven un poco hacia arriba o hacia abajo.

Da el pronóstico ingenuo. Si $X_{t+1} = X_t + Z_{t+1}$ y el paso Z_{t+1} tiene media 0 (es tan probable que suba como que baje), el mejor pronóstico de X_{t+1} es X_t: el valor de mañana se pronostica con el de hoy. Es la referencia contra la que se compara cualquier método de pronóstico más elaborado: si no le gana a "mañana igual que hoy", no sirve.

Una caminata parece tener tendencia, aunque no la tiene



Seis caminatas generadas con **el mismo mecanismo**: pasos al azar de media 0. Ninguna tiene una tendencia, porque nada en el mecanismo empuja hacia arriba ni hacia abajo. Sin embargo, tres terminan muy arriba y tres muy abajo.

Las subidas y bajadas largas son azar acumulado. Ver una serie que sube durante un tiempo no alcanza para decir que tiene tendencia: también podría ser una caminata.

Cómo se mide la memoria: media y autocovarianza

Con una serie observada $x_1, \dots, x_n$:

Media muestral

$$\bar{x} = \frac{1}{n} \sum_{t=1}^{n} x_t$$

Autocovarianza muestral al rezago τ: cuánto varían juntos los valores separados por τ pasos.

$$\text{cov}_x(\tau) = \frac{1}{n} \sum_{t=1}^{n-\tau} (x_t - \bar{x})(x_{t+\tau} - \bar{x})$$

Con $\tau = 0$ es la varianza de la serie.

La autocorrelación

Definición. La **autocorrelación muestral** al rezago τ es

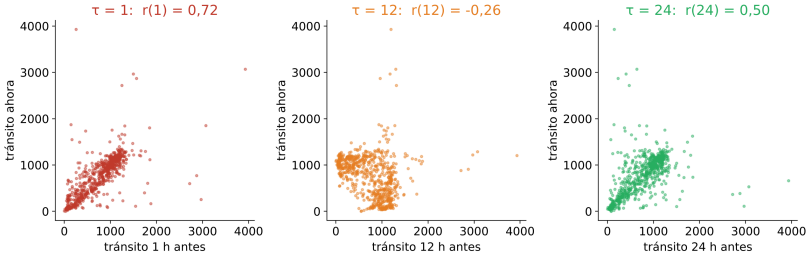
$$r(\tau) = \frac{\text{cov}_x(\tau)}{\text{cov}_x(0)}.$$

- Vale entre -1 y 1, y $r(0) = 1$.
- $r(\tau)$ cerca de 1: lo que pasó hace τ pasos anticipa bien lo de ahora.
- $r(\tau)$ cerca de 0: no hay relación lineal a esa distancia.
- $r(\tau)$ negativo: valores separados por τ tienden a estar en lados opuestos de la media.

Para el ruido blanco la autocorrelación es 0 en todo rezago distinto de 0. Para la caminata es muy alta y decae despacio.

Cada rezago, una comparación

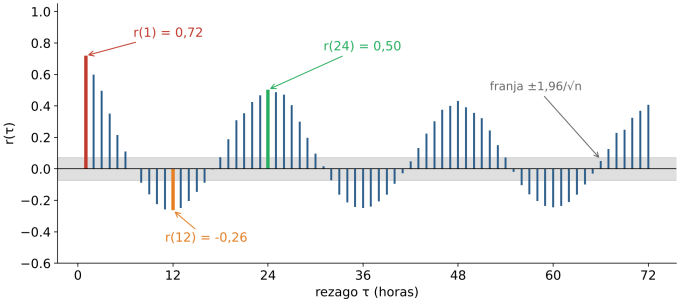
Para calcular $r(\tau)$ se compara cada valor de la serie con el de τ pasos antes. Cada gráfico tiene un punto por hora de junio: el tránsito en ese momento (eje vertical) contra el tránsito τ horas antes (eje horizontal).



- $\tau = 1$: los puntos siguen una diagonal creciente. Una hora se parece a la anterior.
- $\tau = 12$: no hay diagonal creciente. Doce horas antes, de día, el tránsito era alto si ahora, de noche, es bajo.
- $\tau = 24$: vuelve la diagonal. Cada hora se parece a la misma hora del día anterior.

El correlograma

Definición. El **correlograma** es el gráfico que tiene en el eje horizontal el rezago τ y en el eje vertical $r(\tau)$, con una barra por rezago (Rincón y De Jesús Romo, 2024).



Junta en un solo gráfico todas las comparaciones de la diapositiva anterior: las tres barras de color son los tres gráficos de dispersión. La **franja gris** marca $\pm 1{,}96/\sqrt{n}$: si la serie fuera un ruido, el 95% de las barras caería dentro. Una barra fuera de la franja indica que hay memoria a esa distancia.

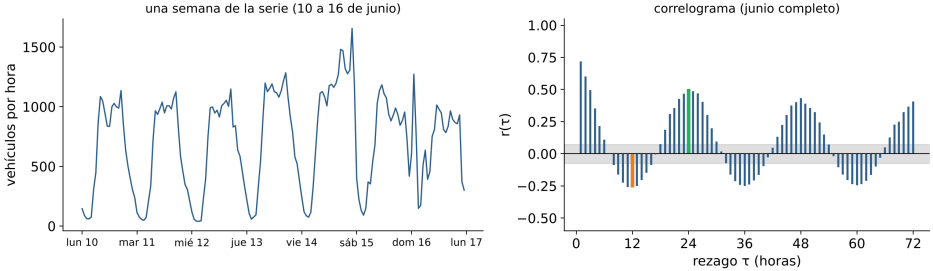
Qué se lee en un correlograma

Se mira la **forma** de las barras que salen de la franja (Mauricio, 2007). Hay tres formas básicas:

- **Cae rápido**: las primeras barras son altas y enseguida quedan dentro de la franja. La memoria es corta: lo que pasó hace unas horas ya no dice nada sobre lo de ahora.
- **Cae lento**: las barras son altas y bajan muy despacio. La memoria es larga: la serie no vuelve a un nivel medio.
- **Es periódico**: las barras suben y bajan con un ritmo. La distancia entre dos picos es el **período**: cada cuánto la serie repite su comportamiento.

En las diapositivas que siguen hay un ejemplo de cada forma, siempre con la serie a la izquierda y su correlograma a la derecha.

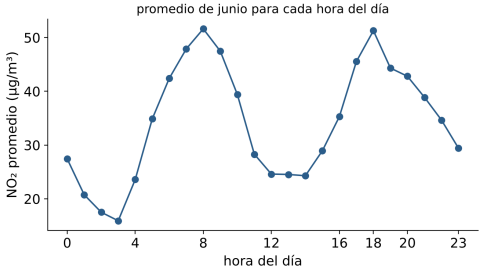
Un correlograma periódico: el tránsito

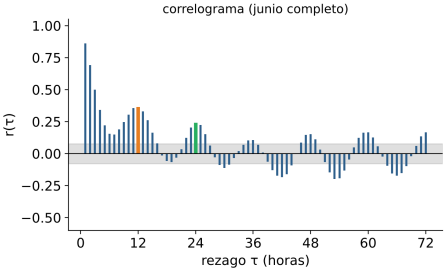


Qué se ve. La serie sube de día y baja de noche, todos los días. En el correlograma las barras suben y bajan, con picos en 24, 48 y 72 horas.

Qué significa. El período es de 24 horas: el tránsito de una hora se parece al de la misma hora del día anterior. En 12 horas la barra es negativa, $r(12) = -0{,}26$: doce horas después, el tránsito suele estar del otro lado de su media.

Un correlograma periódico de 12 horas: el NO_2



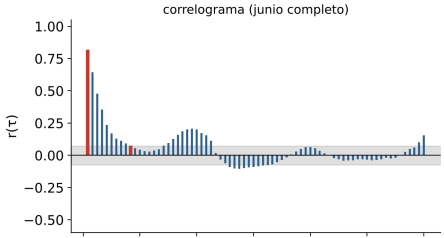


Qué se ve. A la izquierda, para cada hora del día, el promedio del NO_2 en los 30 días de junio: hay dos máximos, a las 8 y a las 18 horas. En el correlograma hay picos en 12 horas, $r(12) = 0{,}36$, y en 24 horas, $r(24) = 0{,}24$.

Qué significa. El período es de 12 horas: cada 12 horas el NO_2 vuelve a estar alto.

Un correlograma que cae rápido: el PM2.5

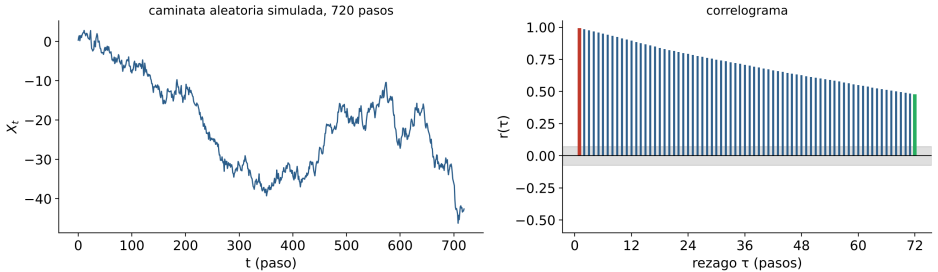




Qué se ve. Picos cortos sobre un piso bajo. En el correlograma, $r(1) = 0{,}82$ y a las 10 horas la barra ya está dentro de la franja, $r(10) = 0{,}07$. En 24 horas hay una joroba chica, $r(24) = 0{,}20$.

Qué significa. La memoria dura pocas horas: un episodio de contaminación se mantiene unas horas y se va. El ciclo diario existe, pero es débil.

Un correlograma que cae lento: la caminata aleatoria

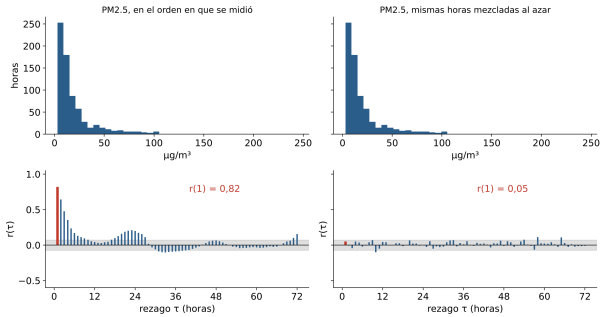


Qué se ve. La caminata se aleja y no vuelve a un nivel medio. Todas las barras son altas y bajan muy despacio: $r(1) = 0{,}99$, $r(24) = 0{,}79$, $r(72) = 0{,}48$.

Qué significa. La memoria es larga: cada valor es el anterior más un paso chico, así que lo de hace 72 pasos todavía se parece a lo de ahora.

La autocorrelación es una propiedad del orden

Se toman las 720 horas de PM2.5 y se **mezclan al azar**: los mismos valores, en otro orden.



Arriba, los histogramas son idénticos: misma media (20,06 μg/m³), misma varianza. **Abajo**, el correlograma de la serie medida cae rápido, $r(1) = 0{,}82$; el de la mezclada queda dentro de la franja, como un ruido, $r(1) = 0{,}05$. La media y el histograma no ven el orden; la autocorrelación sí.

El operador retraso

Definición. El **operador retraso** B corre la serie un paso hacia atrás:

$$B\,x_t = x_{t-1}, \qquad B^k x_t = x_{t-k}.$$

En cada fila, $B\,x_t$ es el valor que la serie tenía una hora antes. En pandas es `shift(k)`; en R, `lag(x, k)`.

hora (1 de junio)	x_t (tránsito)	$B\,x_t$
00:00	192	—
01:00	103	192
02:00	95	103
03:00	94	95
04:00	100	94
05:00	223	100

Curva de Maroñas, vehículos por hora. La primera fila no tiene valor anterior: queda vacía.

Qué es diferenciar una serie

Definición. Diferenciar una serie es reemplazar cada valor por cuánto cambió respecto del valor anterior:

$$\nabla x_t = x_t - x_{t-1} = x_t - B\,x_t.$$

La serie de **niveles** se convierte en una serie de **cambios**.

hora	x_t	$B\,x_t$	∇x_t
00:00	192	—	—
01:00	103	192	-89
02:00	95	103	-8
03:00	94	95	-1
04:00	100	94	6
05:00	223	100	123

Por ejemplo, a la 01:00 la diferencia es $103 - 192 = -89$: pasaron 89 vehículos menos que a las 00:00.

Diferencias: cómo se leen y cómo se deshacen

- Una serie de n valores tiene $n - 1$ diferencias: se pierde el primero.
- Positiva: la serie subió. Negativa: bajó. Cero: no cambió.
- Se puede volver atrás: $x_t = x_1 + \nabla x_2 + \cdots + \nabla x_t$. Sumar las diferencias desde el primer valor reconstruye la serie.

Diferencia de retraso k: $\nabla_k x_t = x_t - x_{t-k}$ compara con el valor de k pasos antes. Con datos mensuales, la **variación interanual** de los diarios es $\nabla_{12}\, x_t$: cada mes contra el mismo mes del año anterior.

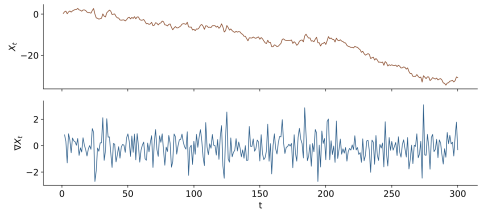
Diferenciar la caminata devuelve el ruido

La caminata se construye sumando ruidos: $X_t = X_{t-1} + Z_t$. Si se despeja Z_t:

$$\nabla X_t = X_t - X_{t-1} = Z_t.$$

Diferenciar deshace la suma: los cambios de la caminata son exactamente los pasos al azar.

t	1	2	3	4
Z_t	0,5	$-1,2$	0,3	0,8
X_t ($X_0 = 0$)	0,5	$-0,7$	$-0,4$	0,4
∇X_t	—	$-1,2$	0,3	0,8



Arriba, una caminata de 300 pasos; abajo, sus diferencias: el ruido con el que se construyó.

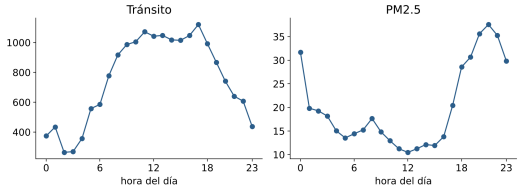
Estacionariedad, en una versión intuitiva

Definición (estacionariedad débil). Una serie es estacionaria si

1. su media no cambia con el tiempo, y
2. la covarianza entre X_t y $X_{t+\tau}$ depende solo de la distancia τ, no de t.

Es decir: el comportamiento de la serie es el mismo en cualquier tramo que se mire.

- El **ruido** es estacionario.
- La **caminata** no: no vuelve a un nivel medio.
- El **tránsito** tampoco: su media depende de la hora del día.



Fuentes

- J. T. Leek y R. D. Peng (2015). What is the question? *Science*, 347(6228), 1314–1315.
- L. Rincón y V. De Jesús Romo (2024). *Una introducción a las series de tiempo*. Facultad de Ciencias, UNAM. Capítulo 1: modelos elementales, funciones básicas, operadores, estacionariedad y correlograma.
- J. A. Mauricio (2007). *Introducción al Análisis de Series Temporales*. Universidad Complutense de Madrid. Sección 2.2: correlograma.
- A. de la Fuente Fernández. *Series temporales*. Universidad Autónoma de Madrid.
- Datos: tránsito, NO_2 y PM2.5, Curva de Maroñas, junio de 2024. Catálogo de Datos Abiertos de Uruguay, Intendencia de Montevideo (`transito_aire_junio2024.csv`, clase 10).
- Encuesta de Factum, segundo bimestre de 2026, publicada en El Observador y VTV Noticias.