Ejercicios de repaso

Introducción a la Ciencia de Datos — Universidad de Montevideo

Nombre: _____ **Fecha:** _____

Trabajo en papel, sin computadora. Los valores de las tablas están inventados.

Cómo leer la letra. Todos los ejercicios tienen dos partes: *Datos* (lo que se tiene) y *Se pide* (lo que hay que hacer). Cada inciso empieza con un verbo, y cada verbo pide siempre el mismo tipo de respuesta:

Verbo	La respuesta es
Escribir	un texto exacto: una ruta, una línea, una lista de valores
Contar	un número entero
Calcular	un número, con la cuenta a la vista
Completar	las celdas vacías de una tabla o los huecos `____`
Clasificar	una opción de la lista que da el inciso
Decidir	sí o no, y un renglón de justificación

El proyecto. Todos los ejercicios usan esta carpeta. NA es una celda vacía.

```
proyecto/
├── datos/
│   ├── crudos/
│   │   ├── jugadores.csv
│   │   ├── felicidad.csv
│   │   ├── presion.csv
│   │   ├── poblacion_ccz.csv
│   │   └── centros_ccz.csv
│   ├── limpios/
│   └── imagenes/
│       └── rodilla_001.jpg
├── scripts/
│   └── limpieza.py
├── salidas/
└── .gitignore
```

Regla de las rutas. Una ruta relativa se busca a partir del *directorio de trabajo*: la carpeta donde está parado el programa (`getwd()` en R, `Path.cwd()` en Python). Salvo que el ejercicio diga otra cosa, el directorio de trabajo es `proyecto/`. Las carpetas se separan con `/`. Dos puntos (`..`) significan «subir una carpeta».

Ejercicio 1 (rutas desde la raíz)**.**

Datos. El directorio de trabajo es `proyecto/`.

Se pide.

a) Escribir la ruta relativa de `jugadores.csv`.

b) Escribir la ruta relativa de `limpieza.py`.

c) Escribir la ruta para guardar un archivo nuevo `tabla.csv` dentro de `salidas`.

d) Contar cuántas carpetas hay que atravesar desde `proyecto/` para llegar a `rodilla_001.jpg`.

Ejercicio 2 (rutas desde otra carpeta)**.**

Datos. El directorio de trabajo es `proyecto/scripts/`.

Se pide.

a) Escribir la ruta relativa de `jugadores.csv`.

b) Escribir la ruta para guardar un archivo nuevo `grafico.png` dentro de `salidas`.

c) Escribir en qué carpeta busca el programa si se le da la ruta `datos/crudos/jugadores.csv`.

d) Decidir si con la ruta del inciso c) el programa encuentra el archivo.

Ejercicio 3 (rutas con errores)**.**

Datos. El directorio de trabajo es `proyecto/`. Se quiere leer `felicidad.csv` y se probaron cinco rutas:

n.º	Ruta escrita
1	`datos/crudos/felicidad.csv`
2	`C:/Users/ana/Desktop/proyecto/datos/crudos/felicidad.csv`
3	`crudos/felicidad.csv`
4	`datos/crudos/felicidad.xlsx`
5	`datos\crudos\felicidad.csv`

Se pide.

a) Clasificar cada ruta: *correcta*, *absoluta* (solo sirve en una computadora), *falta una carpeta*, *nombre de archivo equivocado* o *barra invertida*.

b) Escribir la ruta que corrige a las cuatro que no son correctas.

c) Decidir si la ruta 2 funciona en la computadora de un compañero que clonó el repositorio.

Ejercicio 4 (Git: conflicto)**.**

Datos. En `scripts/limpieza.py`, la línea 12 dice `MIN_PARTIDOS = 10`. Ana la cambia a `MIN_PARTIDOS = 15` y confirma el cambio en la rama `main`. Luis la cambia a `MIN_PARTIDOS = 20` y confirma el cambio en la rama `luis`. Después Luis, desde su rama, fusiona `main`.

Se pide.

a) Decidir si Git puede hacer la fusión sin ayuda.

b) Escribir cómo queda la línea 12 en el archivo, con las marcas que agrega Git.

c) Escribir la línea 12 una vez resuelto el conflicto, si el equipo acuerda usar el valor de Ana.

d) Escribir la línea que hay que agregar a `.gitignore` para que no se suba nada de la carpeta `crudos`.

Ejercicio 5 (tipos y filtro)**.**

Datos. El archivo `jugadores.csv` tiene las columnas `nombre`, `posicion` (arquero, defensa, medio, delantero), `nivel` (bronce, plata, oro), `titular` (sí, no), `goles`, `edad` y `puntaje`. Seis jugadores:

jugador	1	2	3	4	5	6
edad	19	22	25	28	31	34
puntaje	62	71	78	84	90	75

Se pide.

a) Clasificar `posicion`, `nivel`, `titular` y `goles`: *categórica nominal*, *categórica ordinal*, *binaria* o *conteo*.

b) Escribir la máscara booleana `puntaje > 80`: verdadero o falso para cada jugador.

c) Contar cuántos jugadores cumplen `puntaje > 80` y calcular la media de sus puntajes.

d) Escribir los puntajes que cumplen `(edad >= 30) & (puntaje > 80)`.

e) Completar el seudocódigo que hace el filtro del inciso b):

```
CREAR altos VACÍO
PARA CADA p EN puntaje
    SI p ____ 80 ENTONCES
        AGREGAR ____ A altos
    FIN SI
FIN PARA
```

Ejercicio 6 (perfilado)**.**

Datos. El archivo `felicidad.csv` tiene estas filas (índice de felicidad e índice de bienestar mental por país y año). La columna `fila` solo numera los renglones; no está en el archivo:

fila	pais	anio	felicidad	bienestar
1	Uruguay	2022	6,4	71
2	Uruguay	2023	6,5	NA
3	Chile	2022	6,2	68
4	Chile	2023	6,3	69
5	Finlandia	2022	7,8	NA
6	Finlandia	2023	7,7	80
7	Brasil	2023	6,1	64
8	Brasil	2023	6,1	64

Se pide.

a) Escribir la ruta relativa del archivo.

b) Contar las filas, las columnas y los NA de cada columna.

c) Contar las filas repetidas y las filas que quedan al quitarlas.

d) Escribir el identificador de la tabla: las columnas que, juntas, distinguen una fila de otra.

e) Escribir la unidad de observación: qué representa una fila.

f) Contar cuántas filas debería haber con 4 países y 2 años, y escribir cuál falta (faltante implícito).

Ejercicio 7 (fechas y agregación)**.**

Datos. El archivo `presion.csv` tiene la presión sistólica (mmHg) de dos pacientes. La fecha está guardada como texto:

fecha	paciente	sistolica
07/03/2024 08:15	P1	124
07/03/2024 20:10	P1	132
08/03/2024 08:20	P1	128
07/03/2024 08:30	P2	140
07/03/2024 20:05	P2	NA
08/03/2024 08:25	P2	136

Se pide.

a) Escribir la ruta relativa del archivo.

b) Escribir el día, el mes y la hora de la primera fila.

c) Completar la tabla por paciente y día. La media no cuenta los NA; `n` es la cantidad de mediciones con valor.

paciente	dia	media	n
P1	07/03		
P1	08/03		
P2	07/03		
P2	08/03		

d) Calcular la suma de la columna `n`.

e) Decidir si esa suma es correcta, sabiendo que el archivo tiene 6 filas y 1 NA.

Ejercicio 8 (encuesta y faltantes)**.**

Datos. Se sortean $n = 300$ estudiantes para medir un índice de bienestar. Responden $r = 210$, con media $\bar{y}_r = 62$. Los que no respondieron tienen media $\bar{y}_m = 54$. El sesgo de la media es $\frac{m}{n}(\bar{y}_r - \bar{y}_m)$, donde m es la cantidad que no respondió. La pregunta «¿cuántas horas trabaja?» se hace solo a quienes dicen que trabajan. Tres filas de la base:

id	trabaja	horas_trabajo	bienestar
1	No	NA	70
2	Sí	40	NA
3	Sí	NA	55

Se pide.

a) Calcular m y la tasa de respuesta r/n.

b) Calcular el sesgo de la media.

c) Decidir si la media de los que respondieron queda por encima de la media de los 300.

d) Clasificar cada uno de los tres NA: *faltante estructural* (la pregunta no correspondía) o *no respuesta*.

Ejercicio 9 (gráfico de barras)**.**

Datos. La tasa de desempleo es 9,4 % en el departamento A y 6,2 % en el departamento B. Se dibujan dos barras en un cuadro de 10 cm de alto.

Se pide.

a) Calcular la diferencia entre A y B, en puntos y como porcentaje del valor de A.

b) Calcular la altura en cm de cada barra si el eje vertical va de 0 a 10.

c) Calcular la altura en cm de cada barra si el eje vertical va de 5 a 10.

d) Calcular, para el gráfico del inciso c), cuánto más baja se ve la barra de B que la de A, en porcentaje.

e) Decidir si el gráfico del inciso c) muestra bien la diferencia.

Ejercicio 10 (unión de tablas)**.**

Datos. Dos archivos con datos por centro comunal zonal (CCZ):

`poblacion_ccz.csv`		`centros_ccz.csv`	
ccz	poblacion	ccz	centros
CCZ1	45000	CCZ1	3
CCZ2	38000	CCZ2	3
CCZ3	52000	CCZ3	4
CCZ4	30000	CCZ5	1

Se pide.

a) Escribir la ruta relativa de cada archivo.

b) Escribir la columna que sirve de clave para unir las dos tablas.

c) Contar las filas de la unión interna (`inner_join`: solo los CCZ que están en las dos tablas).

d) Contar las filas de la unión izquierda (`left_join`) sobre `poblacion_ccz` y los NA que quedan en `centros`.

e) Calcular los centros cada 10.000 habitantes en CCZ1.

f) Contar las filas de la unión interna si en una de las tablas CCZ2 estuviera escrito `ccz 2`.

Ejercicio 11 (serie de tiempo y rezago)**.**

Datos. Valoración semanal de un jugador. En la semana 3 no jugó:

semana	1	2	3	4	5	6
valoracion	6,8	7,4	NA	8,1	7,9	7,0
valoracion_antes						

Se pide.

a) Completar la fila `valoracion_antes` con el valor de la semana anterior (rezago de un paso).

b) Contar las semanas en que hay valor en las dos filas y escribir esos pares.

c) Decidir si se puede borrar la columna de la semana 3 antes de calcular el rezago.

Ejercicio 12 (respuesta de una API)**.**

Datos. Se envían 50 radiografías de la carpeta `imagenes` a un modelo de lenguaje y se le pide el grado de artrosis (0 a 4) de cada una. La tabla que devuelve tiene este conteo:

grado	0	1	2	3	4
imágenes	12	9	14	8	5

Un especialista coincide con el modelo en 36 de las imágenes respondidas. En otra corrida, una celda de `grado` dice `2/3`.

Se pide.

a) Escribir la ruta relativa de `rodilla_001.jpg`.

b) Contar las imágenes que respondió el modelo y las que faltan.

c) Calcular el porcentaje de coincidencia con el especialista sobre las imágenes respondidas.

d) Clasificar la columna `grado` de la otra corrida: *numérica* o *texto*.

e) Decidir si en esa corrida se puede calcular el promedio de `grado` sin corregir antes la celda.

Ejercicio 13 (desvío y pendiente)**.**

Datos. Un paciente tiene 142 mmHg de presión sistólica; lo habitual en su grupo de edad es 131. Una recta ajustada a los datos de `presion.csv` da una pendiente de 0,6 mmHg por año de edad.

Se pide.

a) Calcular el desvío del paciente respecto de lo habitual.

b) Calcular cuánta presión más se espera en un paciente 10 años mayor.

c) Decidir si la pendiente alcanza para afirmar que la edad causa el aumento de la presión.

Ejercicio 14 (rutas en el repositorio del curso)**.**

Datos. La carpeta `curso/` es el repositorio del curso. El directorio de trabajo es `curso/`. El archivo `.gitignore` contiene la línea `*.csv`.

```
curso/
├── clases/
│   ├── clase7/
│   │   ├── carga_y_transformacion.py
│   │   └── ozono.csv
│   └── clase11/
│       └── clase_ia/
│           ├── leer_ticket.py
│           └── ticket.jpg
├── .gitignore
└── curso.Rproj
```

En `leer_ticket.py` está escrito:

```
RUTA = "clases/clase11/clase_ia/"
FOTO = "ticket.jpg"
archivo = open(RUTA + FOTO, "rb")
```

Se pide.

a) Escribir la ruta relativa de `ozono.csv`.

b) Escribir el texto que resulta de `RUTA + FOTO`.

c) Decidir si el programa encuentra la foto.

d) El directorio de trabajo pasa a ser `curso/clases/clase11/clase_ia/`. Decidir si el programa encuentra la foto.

e) Escribir el valor que debe tener `RUTA` en el caso del inciso d).

f) Decidir si un compañero que clona el repositorio recibe el archivo `ozono.csv`.

Ejercicio 15 (rutas armadas por partes)**.**

Datos. En la computadora de Ana el directorio de trabajo es `C:/Users/ana/curso`. El script tiene estas líneas:

```
BASE_DIR   = Path.cwd()
SUBCARPETA = BASE_DIR / "clases/clase7"
ruta       = SUBCARPETA / "ozono.csv"
```

Se pide.

a) Escribir el valor de `BASE_DIR`.

b) Escribir el valor de `SUBCARPETA`.

c) Escribir el valor de `ruta`.

d) Decidir si el mismo script funciona en la computadora de Luis, donde el directorio de trabajo es `C:/Users/luis/Desktop/curso`.

e) Escribir el valor de `ruta` si Ana ejecuta el script con el directorio de trabajo en `C:/Users/ana/curso/clases/clase7`.

f) Decidir si en el caso del inciso e) el programa encuentra el archivo.

g) En R se escribe `here::here("clases/clase7/ozono.csv")`. Decidir si funciona en el caso del inciso e).

Ejercicio 16 (el archivo no aparece)**.**

Datos. El directorio de trabajo es `curso/`. Al leer `ventas_local.csv` el programa responde `FileNotFoundError` (en R, `cannot open file`). Se lista el contenido del directorio de trabajo en tres situaciones distintas:

Situación	Lo que muestra el listado
1	`clases`, `datos_clase`, `README.md`
2	`clases`, `ventas_locales.csv`, `README.md`
3	`clases`, `ventas_local.xlsx`, `README.md`

Se pide.

a) Clasificar cada situación: *problema de nombre* o *problema de carpeta*.

b) Escribir la ruta correcta en la situación 1, sabiendo que el archivo está dentro de `datos_clase`.

c) Escribir la instrucción que muestra el directorio de trabajo, en R o en Python.

d) Ana propone escribir antes `setwd("C:/Users/ana/curso/datos_clase")`. Decidir si conviene.

Ejercicio 17 (muestra con reposición)**.**

Datos. Cinco mediciones de presión sistólica, numeradas del 1 al 5:

posición	1	2	3	4	5
sistolica	118	126	135	142	121

Se arma una muestra con reposición (*bootstrap*) de cinco valores. El sorteo, con la semilla fijada, da las posiciones 3, 1, 3, 5, 2.

Se pide.

a) Escribir los cinco valores de la muestra.

b) Calcular la media de la muestra y la media de las cinco mediciones originales.

c) Decidir si otra persona que usa la misma semilla obtiene la misma muestra.

d) Decidir si la muestra aporta información nueva sobre los pacientes.

Ejercicio 18 (flujo y carga)**.**

Datos. Un comercio guarda un archivo por mes con una fila por día. Ya están cargados enero (31 filas), febrero (29) y marzo (31). Hoy llega abril (30 filas).

Se pide.

a) Calcular las filas de la tabla antes y después de agregar abril.

b) Contar las filas que se leen hoy con una carga incremental y con una carga completa.

c) Escribir en orden las etapas del flujo de análisis: exploración, entrega de resultados, perfilado, ingesta, transformación, limpieza.

d) Completar el seudocódigo de la lectura con control de codificación:

```
INTENTAR
    Cargar CSV en 'df_raw' (____)
SI FALLA POR CODIFICACIÓN ENTONCES
    IMPRIMIR "[AVISO]: reintentando..."
    Cargar CSV en 'df_raw' (____)
FIN INTENTAR
```

Ejercicio 19 (lectura de un CSV)**.**

Datos. Las primeras líneas de un archivo, abierto como texto:

```
fecha;local;monto
03/01/2024;Pocitos;1250,50
04/01/2024;Unión;980,00
```

Al leerlo aparecen, en distintos intentos, cuatro síntomas:

n.º	Síntoma
1	La tabla queda con una sola columna
2	La columna `monto` queda como texto
3	Se lee `UniÃ³n` en lugar de `Unión`
4	`FileNotFoundError`

Se pide.

a) Escribir el carácter que separa las columnas y el carácter que marca los decimales.

b) Contar las columnas de la tabla bien leída.

c) Clasificar cada síntoma según su causa: *separador*, *decimal*, *codificación* o *ubicación del archivo*.

d) Decidir si hay que modificar el archivo para leerlo bien.

Ejercicio 20 (partes de un gráfico)**.**

Datos. Un gráfico de líneas muestra la tasa de desempleo mensual del departamento A, de enero a abril. En el gráfico aparecen estos elementos:

n.º	Elemento
1	«Tasa de desempleo, departamento A, 2024», arriba
2	«Valores», junto al eje vertical
3	«Ene», «Feb», «Mar», «Abr», bajo el eje horizontal
4	La línea que une los cuatro puntos
5	«Fuente: INE», al pie

Se pide.

a) Clasificar cada elemento: *título*, *etiqueta de eje*, *marcas*, *geometría* o *fuente*.

b) Escribir el texto que debe reemplazar a «Valores», con la variable y la unidad.

c) Decidir si este gráfico necesita leyenda.

d) Decidir si necesita leyenda cuando se agrega la línea del departamento B.

e) Decidir si conviene dibujar en el mismo eje el desempleo (%) y la población (miles de personas).

Ejercicio 21 (apilar tablas)**.**

Datos. Centros de salud por centro comunal zonal en dos años:

`centros_2023`		`centros_2024`	
ccz	centros	ccz	centros
CCZ1	2	CCZ1	3
CCZ2	3	CCZ2	3
CCZ3	4	CCZ3	4
		CCZ5	1

Se pide.

a) Escribir la columna que hay que agregar a cada tabla antes de apilarlas, para saber de qué año es cada fila.

b) Contar las filas y las columnas de la tabla apilada (`bind_rows` en R, `pd.concat` en Python).

c) Completar el total de centros por año:

anio	centros
2023	
2024	

d) Calcular la variación del total entre 2023 y 2024.

e) Decidir si apilar dos tablas es lo mismo que unirlas por una clave.

Ejercicio 22 (grilla de tiempo regular)**.**

Datos. Un sensor midió en horarios irregulares:

hora	10:02	10:07	10:14	10:31	10:38
valor	20	24	30	28	32

Se arma una grilla regular con bloques de 10 minutos. Cada medición va al bloque que empieza antes (10:07 va al bloque 10:00).

Se pide.

a) Completar la tabla. Si un bloque no tiene mediciones, la media es NA y `n` es 0.

bloque	10:00	10:10	10:20	10:30
media				
n				

b) Contar los bloques sin mediciones.

c) Calcular cuántos bloques de 10 minutos tiene un día.

d) Decidir si el bloque sin mediciones se puede quitar de la grilla.

Ejercicio 23 (lectura de un ticket por API)**.**

Datos. Se envía la foto de un ticket a un modelo de lenguaje y se le pide una tabla. Devuelve:

descripcion	monto
LECHE FRESCA	62.00
PAN FRANCES	48.50
ARROZ 1 KG	89.50

El total impreso en el ticket es 200.00. En una segunda lectura de la misma foto, el monto del pan viene como `48.50`, con la letra O. La clave de la API está guardada en el archivo `clave_gemini.txt`.

Se pide.

a) Calcular la suma de la columna `monto`.

b) Decidir si la tabla coincide con el total impreso.

c) Clasificar la columna `monto` de la segunda lectura: *numérica* o *texto*.

d) Decidir si `clave_gemini.txt` se sube al repositorio.

e) Escribir la línea que hay que agregar a `.gitignore` para ese archivo.