Ejercicios de repaso (segunda serie)

Introducción a la Ciencia de Datos — Universidad de Montevideo

Nombre: Fecha:

Trabajo en papel, sin computadora. Los valores de las tablas están inventados, salvo que el ejercicio diga que salen de la tabla de la clase 12.

Cómo leer la letra. Todos los ejercicios tienen dos partes: *Datos* (lo que se tiene) y *Se pide* (lo que hay que hacer). Cada inciso empieza con un verbo, y cada verbo pide siempre el mismo tipo de respuesta:

Verbo	La respuesta es
Escribir	un texto exacto que no es código: una ruta, un nombre, un valor
Contar	un número entero
Calcular	un número, con la cuenta a la vista
Completar	las celdas vacías de una tabla o los huecos ____
Clasificar	una opción de la lista que da el inciso
Decidir	sí o no, y un renglón de justificación
Programar	código en Python, escrito en la hoja

Solo el verbo Programar pide código. Con cualquier otro verbo la respuesta no lleva código. Cuando hay que programar, el ejercicio dice cómo se llama la tabla y qué columnas tiene; se usan esos nombres.

Para ir más lejos. Algunos ejercicios terminan con incisos bajo ese título. Son opcionales: se hacen después de terminar el resto.

La tabla de la clase 12. `transito_aire_junio2024.csv` tiene una fila por estación y hora de junio de 2024, con las columnas `estacion`, `hora`, `transito` (vehículos por hora cerca de la estación), `no2` y `pm25` (µg/m³). Las estaciones son Tres Cruces, Curva de Maroñas y Museo Romántico.

Python. Se supone que ya se corrió:

```
import numpy as np
import pandas as pd
import statsmodels.formula.api as smf
```

Ejercicio 24 (faltantes y una variable nueva).

Datos. La tabla se llama `aire` y tiene estas filas (NA es una celda vacía; la columna fila solo numera los renglones):

fila	estacion	hora	transito	pm25
1	Tres Cruces	2024-06-03 08:00	31200	18,4
2	Tres Cruces	2024-06-03 09:00	NA	22,0
3	Tres Cruces	2024-06-03 10:00	35800	NA
4	Museo Romántico	2024-06-03 08:00	2900	9,5
5	Museo Romántico	2024-06-03 09:00	3400	NA
6	Museo Romántico	2024-06-03 10:00	4100	31,0

Se crea la columna `transito_miles`, que es `transito` dividido 1000.

Se pide.

a) Contar los NA de cada columna de `aire`.
b) Completar la columna `transito_miles` para las seis filas.
c) Contar los NA de `transito_miles`.
d) Programar la línea que crea `transito_miles` en la tabla `aire`.
e) Programar la línea que muestra cuántos NA tiene cada columna de `aire`.

Para ir más lejos. Se crea otra columna con esta línea:

```
aire["pm25_alto"] = np.where(aire["pm25"] > 25, "alto", "bajo")
```

f) Completar la columna `pm25_alto` para las seis filas. (En Python, NA > 25 da `False`.)
g) Decidir si las filas 3 y 5 quedan bien clasificadas.

Ejercicio 25 (variables a partir de la hora).

Datos. La tabla se llama `datos`. Su columna `hora` es una fecha, y tiene estos seis valores. El 1 de junio de 2024 fue sábado.

fila	hora	h	franja	tipo_dia
1	2024-06-01 03:00			
2	2024-06-02 12:00			
3	2024-06-03 05:00			
4	2024-06-03 06:00			
5	2024-06-05 17:00			
6	2024-06-07 18:00			

Las franjas son: madrugada de 0 a 5, mañana de 6 a 11, tarde de 12 a 17 y noche de 18 a 23. El tipo de día es «fin de semana» o «lunes a viernes». En Python, `datos["hora"].dt.hour` da la hora del día, y `datos["hora"].dt.dayofweek` da el día de la semana con lunes = 0, …, sábado = 5, domingo = 6.

Se pide.

a) Completar la columna `h` (hora del día).
b) Completar la columna `franja`.
c) Completar la columna `tipo_dia`.
d) Contar las filas de cada franja.
e) Programar la línea que crea la columna `h`.
f) Programar la línea que crea la columna `tipo_dia`, usando `np.where`.

Para ir más lejos. En clase la franja se creó con `pd.cut(datos["h"], bins=[-1, 5, 11, 17, 23], labels=[...])`. Cada intervalo de `pd.cut` no incluye su extremo izquierdo e incluye el derecho: el primero es «más de −1, hasta 5».

g) Si se escribe `bins=[0, 5, 11, 17, 23]`, completar la franja que les toca a h = 0 y a h = 5.
h) Decidir si con `bins=[0, 5, 11, 17, 23]` la madrugada queda completa.

Ejercicio 26 (promedios por grupo).

Datos. La tabla se llama `tc` y tiene ocho horas de Tres Cruces. El tránsito está en miles de vehículos por hora:

franja	transito	pm25
madrugada	10	18
madrugada	12	22
mañana	28	16
mañana	30	NA
tarde	38	15
tarde	40	19
noche	24	30
noche	22	34

Se pide.

a) Completar la tabla por franja. La media no cuenta los NA; n es la cantidad de valores de `pm25` con dato.

franja	media de transito	media de pm25	n
madrugada			
mañana			
tarde			
noche			

b) Escribir la franja con más tránsito y la franja con más PM2.5.
c) Decidir si, en esta tabla, el PM2.5 de una franja sigue al tránsito de esa misma franja.
d) Programar la línea que calcula la media de `transito` y de `pm25` para cada franja y la guarda como `por_franja`.

Para ir más lejos.

e) Calcular la media de `pm25` de las siete filas con dato, y el promedio de las cuatro medias del inciso a).
f) Decidir si el promedio de las cuatro medias es la media de `pm25` de la tabla.

Ejercicio 27 (tránsito relativo).

Datos. La columna `transito` suma los vehículos de los puntos de conteo que están a menos de 1,5 km de cada estación. La estación A tiene 2 puntos de conteo cerca; la estación B tiene 40. Tres horas de un mismo día:

estacion	hora	transito	transito_rel
A	08:00	200	
A	13:00	400	
A	20:00	300	
B	08:00	6000	
B	13:00	9000	
B	20:00	9000	

El tránsito relativo es el tránsito de la hora dividido el tránsito medio de su estación: 1 es lo habitual de la estación, 2 es el doble.

Se pide.

a) Calcular el tránsito medio de cada estación.
b) Completar la columna `transito_rel`, con dos decimales.
c) Calcular cuántas veces es el tránsito medio de B respecto del de A.
d) Decidir si eso quiere decir que cerca de B pasan esas veces más vehículos que cerca de A.
e) Programar la línea que crea `transito_rel` en la tabla `datos`, usando `groupby("estacion")` y `transform("mean")`.

Para ir más lejos.

f) Escribir la estación en la que la hora 13:00 está más por encima de lo habitual.

Ejercicio 28 (correlación).

Datos. Coeficientes de correlación calculados con la tabla de la clase 12:

n.º	Estación	Variables	r
1	Tres Cruces	tránsito y NO2	0,59
2	Curva de Maroñas	tránsito y NO2	0,15
3	Tres Cruces	NO2 y PM2.5	0,40
4	Curva de Maroñas	NO2 y PM2.5	0,55
5	Tres Cruces	tránsito y PM2.5	−0,02

En este curso, la intensidad se clasifica así: débil si el valor absoluto de r es menor que 0,3; moderada entre 0,3 y 0,7; fuerte si es mayor que 0,7. La tabla `tc` tiene las horas de Tres Cruces con dato de NO2.

Se pide.

a) Clasificar cada coeficiente por su signo (positiva o negativa) y por su intensidad (débil, moderada o fuerte).
b) Decidir si el coeficiente 1 alcanza para afirmar que el tránsito causa el NO2.
c) Decidir si los coeficientes 1 y 2 permiten afirmar que el tránsito contamina más en Tres Cruces que en Curva de Maroñas.
d) Programar la línea que calcula la correlación entre `transito` y `no2` en la tabla `tc`.

Para ir más lejos. Cinco pares de valores:

x	1	2	3	4	5
y	2	4	5	4	5

La fórmula es $r = \dfrac{\sum (x-\bar{x})(y-\bar{y})}{\sqrt{\sum (x-\bar{x})^2 \, \sum (y-\bar{y})^2}}$. Dato: $\sqrt{60} \approx 7{,}75$.

e) Calcular las medias de x y de y.
f) Calcular r.
g) Clasificar r por su signo y su intensidad.

Ejercicio 29 (la recta).

Datos. Con las 291 horas de Tres Cruces que tienen NO2 se ajustó la recta

$$\text{no2} = 18{,}3 + 0{,}79 \cdot \text{transito_miles}$$

con $R^2 = 0{,}35$. El tránsito de esas horas va de 4,7 a 48,8 miles de vehículos por hora. La tabla se llama `tc`.

Se pide.

a) Calcular el NO2 que da la recta para 0, 10 y 30 mil vehículos por hora.
b) Calcular el residuo de una hora con 30 mil vehículos y un NO2 medido de 50 µg/m³. (Residuo = valor medido − valor que da la recta.)
c) Clasificar esa hora: queda por encima o por debajo de la recta.
d) Clasificar cada uno de los números 18,3, 0,79 y 0,35 con una de estas opciones:
   (i) el NO2 que la recta le asigna a una hora sin tránsito; (ii) cuánto sube el NO2 por cada mil vehículos más por hora; (iii) la parte de la variación del NO2 que explica la recta.
e) Programar las líneas que ajustan la recta, la guardan como `modelo` y muestran los coeficientes y el R^2.

Para ir más lejos.

f) Calcular cuántos miles de vehículos por hora hacen falta para que la recta dé 50 µg/m³.
g) Decidir si conviene usar la recta para una hora con 80 mil vehículos.

Ejercicio 30 (una variable categórica en el modelo).

Datos. El modelo `no2 ~ transito_miles + pm25 + franja`, ajustado con la tabla `tc`, da estos coeficientes:

Coeficiente	Valor
Intercept	9,08
transito_miles	0,65
pm25	0,45
franja[T.mañana]	2,80
franja[T.tarde]	5,41
franja[T.noche]	6,21

Se pide.

a) Escribir la franja de referencia: la que no tiene coeficiente propio.
b) Calcular el NO2 que da el modelo para una hora de la noche con 20 mil vehículos y PM2.5 = 30.
c) Calcular el NO2 que da el modelo para una hora de la madrugada con el mismo tránsito y el mismo PM2.5.
d) Calcular la diferencia entre b) y c).
e) Decidir si esa diferencia cambia cuando el tránsito es de 40 mil vehículos.
f) Programar la línea que crea en `tc` la columna `noche`: 1 si la franja es «noche» y 0 si no.
g) Programar las líneas que ajustan el modelo con `transito_miles`, `pm25` y `noche`, y muestran los coeficientes.

Para ir más lejos. En el modelo con interacción `no2 ~ transito_miles * franja`, el coeficiente de `transito_miles` es 2,94 (la pendiente de la madrugada) y el de `transito_miles:franja[T.mañana]` es $-2{,}42$.

h) Calcular la pendiente del tránsito en la mañana.
i) Decidir si, en la madrugada, mil vehículos más por hora suben el NO2 más que en la mañana.

Ejercicio 31 (rutas en la clase 12).

Datos. La carpeta `curso/` es el repositorio del curso. El archivo `.gitignore` contiene la línea `*.csv`.

```
curso/
├── clases/
│   ├── clase10/
│   │   └── transito_aire_junio2024.csv
│   └── clase12/
│       ├── clase12_ejercicios.py
│       └── clase12_soluciones.py
└── .gitignore
```

En `clase12_ejercicios.py` está escrito:

```
RUTA = "clases/clase10/transito_aire_junio2024.csv"
```

Se pide.

a) Decidir si el programa encuentra el archivo cuando el directorio de trabajo es `curso/`.
b) Escribir en qué carpeta busca el archivo cuando el directorio de trabajo es `curso/clases/clase12/`.
c) Escribir la ruta relativa correcta para el caso del inciso b).
d) Programar la línea que lee el archivo, con la columna `hora` como fecha, y lo guarda como `aire`.
e) Programar las líneas que muestran el directorio de trabajo.

Para ir más lejos.

f) Decidir si un compañero que clona el repositorio recibe el archivo CSV.

Ejercicio 32 (perfilado de la tabla de la clase 12).

Datos. La tabla `aire` tiene tres estaciones, una fila por estación y hora, del 1 al 30 de junio de 2024. Museo Romántico no tiene ningún dato de NO2. Tres Cruces tiene 429 NA en `no2`.

Se pide.

a) Calcular cuántas filas tiene la tabla.
b) Escribir el identificador de la tabla: las columnas que, juntas, distinguen una fila de otra.
c) Escribir la unidad de observación: qué representa una fila.
d) Calcular el porcentaje de horas de Tres Cruces que tienen dato de NO2.
e) Decidir si se puede comparar el NO2 de las tres estaciones.
f) Programar la línea que cuenta cuántas filas tiene cada estación.

Para ir más lejos.

g) Un día de Tres Cruces tiene solo 6 horas con dato de NO2, todas entre las 10 y las 15. Decidir si el promedio de esas 6 horas representa al día.

Ejercicio 33 (unir dos tablas por la hora).

Datos. Dos tablas de una misma estación y un mismo día:

Tabla `ozono`:

hora	o3
08:00	40
09:00	45
10:00	52
11:00	58

Tabla `pm`:

hora	pm25
09:00	12
10:00	15
11:00	14
12:00	18

Se pide.

a) Escribir la columna que sirve de clave para unir las dos tablas.
b) Contar las filas de la unión interna (`how="inner"`: solo las horas que están en las dos tablas).
c) Contar las filas de la unión izquierda sobre `ozono` (`how="left"`) y los NA que quedan en `pm25`.
d) Programar la línea que hace la unión interna y la guarda como `juntas`.
e) Programar la línea que hace la unión izquierda sobre `ozono`.

Para ir más lejos. Por un error de carga, la tabla `pm` tiene dos filas con hora 10:00 (pm25 = 15 y pm25 = 16).

f) Contar las filas de la unión interna.
g) Decidir si la unión avisa del error.